



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

박사학위 청구논문

지도교수 전홍석

유해조류의 적응을 방지하기 위한
딥러닝과 강화학습을 활용한 퇴치
시스템의 구현

2020년 2월

건국대학교 대학원

컴퓨터공학과

이철원

유해조류의 적응을 방지하기 위한 딥러닝과 강화학습을 활용한 퇴치 시스템의 구현

Implementation of Repelling System Using
Deep Learning and Reinforcement Learning
to Prevent Adaptation of Harmful Birds

이 논문을 공학 박사학위 청구논문으로 제출합니다

2019년 11월

건국대학교 대학원

컴퓨터공학과

이철원

이철원의 공학 박사학위 청구논문을 인준함

심사위원장 _____ 강 현 규 _____ (인)

심사위원 _____ 고 명 철 _____ (인)

심사위원 _____ 오 염 덕 _____ (인)

심사위원 _____ 이 준 동 _____ (인)

심사위원 _____ 전 홍 석 _____ (인)

2019년 11월

건국대학교 대학원

목 차

표 목 차	iii
그림목차	iv
ABSTRACT	vi
 제1장 서론	 1
 제2장 관련 연구	 7
제1절 조류 탐지 기법	7
제2절 유해조류 퇴치 기법	9
 제3장 유해조류의 적응을 방지하기 위한 딥러닝과 강화학습을 활 용한 퇴치 시스템	 10
제1절 탐지 : Wild Bird Behavior Classification 알고리즘	11
1. Frame Separation	12
2. Training	14
3. Detection	16
제2절 퇴치 : Anti-adaptation Wild Birds Repelling 알고리즘	17
1. Framework	14
2. 강화 학습 이론을 적용하기 위한 환경 구성	23
3. AWBR 알고리즘의 구현	25
 제4장 실험	 27
제1절 WBBC 알고리즘의 성능 평가	27
1. 실험 환경	27

2. 데이터 세트	27
3. 행동에 따른 조류 분류 기법의 성능 평가	28
4. WBBC 알고리즘의 성능 평가	31
제2절 AWBR 알고리즘의 성능 평가	38
1. 실험 환경	38
2. 유해조류 적용의 검증	41
3. 소리와 볼륨의 조합에 따른 유해조류 퇴치 효과 비교	43
4. AWBR 알고리즘의 성능 평가	46
제5장 결론	48
참고문헌	50
국문초록	54

표 목 차

<표 1> 학습에 사용한 야생조류의 종	27
<표 2> Behavior Classification과 Normal 모델의 검증 결과	29
<표 3> 비교된 알고리즘들의 초당 처리 가능 프레임 성능 비교	36
<표 4> WBBC 알고리즘과 기존 야생 조류 탐지 알고리즘의 비교 결과	37

그 립 목 차

<그림 1> 전통식부터 현대식까지 다양한 유해조류 퇴치 장치	1
<그림 2> 단순한 환경과 복잡한 환경에서 Subtraction 결과 차이	3
<그림 3> 행동과 종에 따른 조류의 외형 변화	4
<그림 4> 유해조류의 적응을 방지하기 위한 딥러닝과 강화학습을 활용한 퇴치 시스템의 구성	10
<그림 5> Wild Bird Behavior Classification(WBBC) 알고리즘 구조	11
<그림 6> VGG-16 모델을 사용한 224p 해상도 모드의 네트워크 모델 구조	15
<그림 7> Anti-adaptation Wild Birds Repelling(AWBR) 알고리즘의 구조	17
<그림 8> AWBR 알고리즘에서 $Situation S_n$ 의 구성	23
<그림 9> 유해조류의 적응 판단 기준 Long-term과 Short-term	24
<그림 10> 구현된 AWBR 알고리즘의 동작 시나리오	25
<그림 11> 폐쇄적인 케이지 환경에서 구현된 AWBR 알고리즘의 동작의 스냅샷	26
<그림 12> Accuracy와 Error Rate의 평가 예시	29
<그림 13> Behavior Classification와 Normal 모델의 검증 결과물 비교	30
<그림 14> SIFT 알고리즘을 사용한 야생 조류 탐지 결과	31
<그림 15> SURF 알고리즘을 사용한 야생 조류 탐지 결과	32
<그림 16> Optical Flow 알고리즘을 사용한 야생 조류의 이동 밀도 탐지 예시	33
<그림 17> Optical Flow 알고리즘을 사용한 야생 조류 탐지 결과	33
<그림 18> HOG+SVM 알고리즘을 사용한 야생 조류 탐지 결과	34
<그림 19> WBBC 알고리즘을 사용한 야생 조류 탐지 결과	35
<그림 20> 실험 환경	38
<그림 21> 실험에 사용한 유해조류	39
<그림 22> 폭발(Explosion) 위협 소리의 시각화	40
<그림 23> 천적(Natural enemy) 위협 소리의 시각화	40

<그림 24> 잡음(Noise) 위협 소리의 시각화	40
<그림 25> 비자극과 자극 환경의 야생 조류의 먹이 섭취량 변화	42
<그림 26> 비자극(Non-stimulust)와 자극(Stimulus) 환경의 야생조류 먹이 섭취량 변화 실험의 스냅샷	42
<그림 27> 소리 위협의 종류에 따른 유해조류 퇴치 효과 실험 스냅샷	43
<그림 28> 직박구리에 대한 위협 소리와 볼륨의 조합별 효과	44
<그림 29> 박새에 대한 위협 소리와 볼륨의 조합별 효과	45
<그림 30> AWBR 알고리즘과 기존 재생 패턴들의 비교	46

ABSTRACT

Implementation of Repelling System Using Deep Learning and Reinforcement Learning to Prevent Adatpation of Harmful Birds

Lee, Cheol won

Department of Computer Engineering
Graduate School of Konkuk University

Since humans began farming, wild birds have been seriously damaging various agricultural environments, such as orchards. Various methods have been studied to repel these wild birds, but wild birds are still causing damage by adapting new methods of repelling because of their biological characteristics. Therefore, research is needed to prevent the adaptation of these wild birds.

In order to prevent adaptation of wild birds, In this paper, detection and repelling algorithm are proposed. The detection algorithm is a Wild Bird Behavior Classification(WBBC) that can accurately detect wild birds using the Deep Learning and wild bird behavior classification method even in a complicated agricultural environment such as orchards. The repelling algorithm is Anti-adaptation Wild Birds Repelling(AWBR) that can prevent the adaptation of wild birds through the learning to responding wild bird using the Monte Calro theory of Reinforcement Learning.

We have verified the proposed WBBC and AWBR algorithm through experiments. The WBBC algorithm is improved the detection

accuracy of 3.6% according to wild bird's behavior classification method using Faster R-CNN than general methods and achieved an average detection accuracy of 95.7% in various our experiment environments. The AWBR algorithm evaluated the adaptation prevention performance using the captured wild birds in around orchard, such as the Brown-eared Bulbul, Great Tit, and Eurasian Magpie. This repelling algorithm has verified that the adaptation prevention effect through learning wild bird by long-term and short-term policy is improved by 43.5% longer than previous threat sound playing methods.

Keyword : Deep Learning, Reinforcement Learning, Machine Learning, Computer Vision, Smart Farm,

제1장 서론

농업이 시작된 이후로 지금까지 유해조류 퇴치는 끊임없이 연구되어지는 하나의 연구 분야이다. 유해조류는 농작물을 먹어치우는 것과 같이 인간에게 해를 입히는 조류를 의미하며 까치, 직박구리, 박새, 비둘기, 참새가 대표적이다. 실제로 논, 밭, 농장 및 과수원과 같은 대부분의 야외 농업 환경이 유해조류로부터 피해를 받고 있으며, 특히나 과수원과 같이 열매를 수확하는 환경은 야생 조류가 열매를 한 번만 쪼아도 상품성을 잃어버리기 때문에 심각한 피해가 발생하고 있다. 이러한 유해조류 피해를 방지하기 위해서 과거의 퇴치 기법(허수아비, 풍선, 연, 라디오, 사운드건)부터 현대적인 기법(초음파 퇴치기, 센서 기반 퇴치기)까지 다양한 장치들이 연구되어졌다.



<그림 1> 전통식부터 현대식까지 다양한 유해조류 퇴치 장치. (a) 허수아비. (b) 풍선. (c) 폭음 총. (d) 초음파 퇴치기. (e) 센서기반 퇴치기.

하지만 그림 1과 같은 대부분의 퇴치 기법들은 초기에는 효과가 있지만 시간이 흐른 뒤에는 효과가 점점 떨어지는 문제가 발생한다. 이는 유해조류가 퇴치 기법들을 학습하고 적응할 수 있기 때문이다[1]. 유해조류의 적응 능력은 조류의 생물학적인 기원에 근거한다. 조류는 일생 동안 날개를 통해 먼 거리를 이동하면서 최적의 서식지를 찾으면서 지금까지 진화해왔다[2]. 따라서 먼 거리를 이동할 수 있는 환경 변화를 자주 접하게 되었고, 결과적으로는 생존을 위해서 새로운 환경에 빠르게 적응할 수 있게 되었다. 유해조류는 이러한 조류의 생물학적인 특성으로 인해 퇴치 기법들을 하나의 새로운 환경으로 인식하고 적응하게 되며, 이 적응 때문에 퇴치 기법들이 점점 효과를 상실하는 문제가 발생한다. 따라서 유해조류로부터 발생하는 농작물의 피해를 줄이기 위해서는 적응을 방지할 수 있는 퇴치 기법이 필요하다.

현재 유해조류 퇴치 장치는 비반응형 퇴치 기법과 반응형 퇴치 기법으로 구분할 수 있다. 비반응형 퇴치 기법은 허수아비, 연, 풍선, 폭음 총 그리고 라디오와 같이 유해조류의 침입과 상관없이 동작하는 장치들을 의미하며, 주기적 혹은 반복적으로 퇴치 위협을 발생시키는 형태가 일반적이다[3]. 따라서 비반응형 퇴치 기법에서 발생하는 위협은 야생 조류의 침입 여부를 고려하지 않기 때문에 유해조류가 위협을 환경으로 빠르게 인식하게되는 문제가 있다. 따라서 이러한 문제를 해결하기 위해서, 센서를 통해 유해조류를 감지하고 퇴치 위협을 가하는 형태의 현대적인 반응형 퇴치 기법들이 연구되어지고 있다[4-12]. 실제로 반응형 기법들은 비반응형 유해조류 퇴치 기법에 비해서 긴 시간동안 작물을 보호할 수 있는 것으로 알려져 있다. 하지만 반응형 기법은 환경에서 유해조류를 정확하게 탐지하지 못할 경우 동작하지 않기 때문에 탐지 능력이 매우 중요하다.

실제로 농업 뿐만 아니라 다양한 시설의 환경에서 조류 피해를 입고 있는 까닭에 초음파, 레이더, 레이저, 그리고 비전과 같은 다양한 센서들이 활용된 조류 탐지 기법들이 연구되어지고 있다[13-19][20-23]. 유해조류를 탐지할 수 있는 센서들 중에서 초음파, 레이더, 그리고 레이저와 같은 거리 기반 센서들이 활용된 탐지 기법들은 다양한 객체가 존재하는 과수원과 같은 환경에서 침입하는 유해조류와 환경에 존재하는 다른 객체들(바람에 흔들리는 나뭇잎, 나뭇가지)을 구분할 수 없는 문제가 있다[13-16].

따라서 과수원과 같은 환경에서 조류를 구분하여 탐지하기 위해서는 비전센서를 사용해야 한다. Scale-Invariant Feature Transform(SIFT), Speeded-Up Robust Features(SURF), Optical Flow, 그리고 Histogram of Oriented Gradients(HoG)+ Support Vector Machine(SVM)과 같은 이미지의 객체에서 특징을 추출 할 수 있는 대표적인 이미지 처리(Image Processing) 알고리즘들이 활용된 다양한 조류 탐지 연구들이 제안되어졌다[17-19]. 하지만 기존의 이미지에서 객체의 특징을 추출하는 방식의 이미지 처리 기법들은 조류를 탐지하기 위해서 사람이 개입하여 각 환경과 야생 조류 종의 외형의 특징을 정의해야만 이미지에서 객체를 분류 할 수 있다. 그리고 이러한 이미지 프로세싱 기법은 정의되는 모든 특징을 루프를 통해 비교하기 때문에 큰 규모의 연산이 발생한다. 이러한 이미지 프로세싱 알고리즘의 연산

량을 줄이기 위한 Subtraction과 같은 기법이 제안되었지만, 이 기법은 복잡한 과수원과 같은 환경에서는 객체를 추출이 어렵기 때문에 사용하는 것이 비효율적이다. 예를 들면 그림 2 (a)의 결과 (b)처럼 단순한 배경에서는 좋은 성능을 보이지만, 복잡한 환경 그림 2 (c)의 결과 (d)에서는 야생 조류를 구분하기가 어렵다. 이렇듯 이미지에서 객체를 찾는 것은 굉장히 유용하지만 특징 정의의 어려움 때문에 사용하는 것이 매우 제한적이었다.



(a)



(b)



(c)

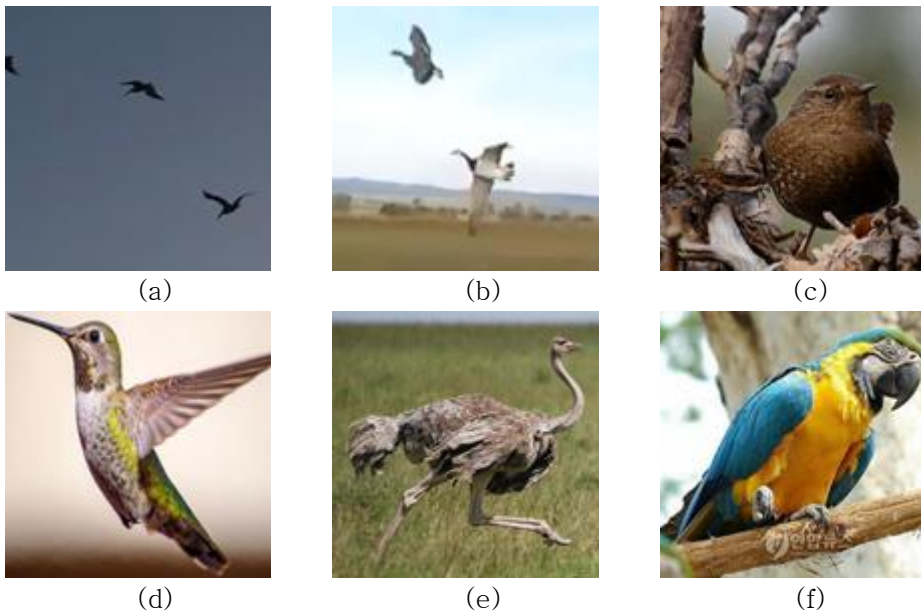


(d)

<그림 2> 단순한 환경과 복잡한 환경에서 Subtraction 결과 차이. (a) 단순한 환경. (b) 단순한 환경에서 Subtraction 기법의 결과. (c) 복잡한 환경. (d) 복잡한 환경에서 Subtraction 기법의 결과.

하지만 최근 딥러닝(Deep Learning)의 발전으로 인해 기존의 이미지 프로세싱에서 발생하던 특징 정의 문제를 사람의 개입 없이 기계가 학습을 통해 특징을 추출하는 방식으로 사람보다 더 높은 정확도로 객체를 구분할 수 있게 되었다. 딥러닝은 사람이 분석하기 어려운 거대한 규모의 데이터를 학습 하고 분석 할 수 있는 기법으로, 특히 매년 이미지넷에서 개최하는 ILSVRC(ImageNet Large Scale Visual Recognition Challenge) 대회에서 딥러닝은 이미 인간 이상의 객체 분류 능력을 보여 주고 있다[20]. 딥러닝은 데이터에 존재하는 패턴을 층층이 쌓여진 깊은 구조의 계층을 통해서 가중치를 조정하여 모델화하는 머신러닝(Machine Learning) 기법의 일종이다.

따라서 조류를 탐지하기 위해 Convolutional neural network(CNN), Faster R-CNN과 같은 딥러닝 알고리즘들을 활용한 연구들 또한 제안되어졌다 [21-23]. 하지만 딥러닝으로 조류를 탐지하는 것은 여전히 어려운 일이다. 왜냐하면 조류의 학습이 어렵기 때문이다. 조류는 생물이기 때문에 그림 3의 a, b, c와 같이 거리에 따라서 그리고 움직임에 따라서 다른 외형을 보인다. 또한 d, e, f와 같이 종에 따라서도 부리모양, 목, 다리, 날개, 색과 같은 외형이 큰 차이가 난다. 따라서 딥러닝이 이렇게 다양한 특징들을 조류로 학습하게되면, 조류로 구분하기 위해 너무 많은 특징을 기준으로 분류하려다가 오히려 정확도가 떨어지는 오버피팅(Over-fitting) 문제가 발생할 수 있으며, 이는 조류 탐지 정확도를 떨어뜨리는 원인이 된다.



<그림 3> 행동과 종에 따른 조류의 외형 변화. (a) 원거리에서 비행하는 조류. (b) 근거리에서 비행하는 조류. (c) 나뭇가지에 앉아있는 조류. (d) 벌새. (e) 타조. (f) 앵무새.

따라서 우리는 이러한 오버피팅 문제를 회피하기 위해 조류의 행동을 Flying과 Staying으로 구분하여 분류하는 방법을 적용하며, 딥러닝 기법인 Faster R-CNN을 활용한 조류 탐지 기술인 Wild Bird Behavior Classification (WBBC) 알고리즘을 제안한다. WBBC 알고리즘은 과수원과 같은 복잡한 환경에서 조류를 탐지하기 위해 딥러닝 기법인 Faster R-CNN

을 사용하며, 딥러닝이 학습시 발생하는 오버피팅 문제로 인한 탐지 정확도 저하 문제는 조류의 행동에 따라 데이터를 정규화 하는 방법을 통해 개선한다.

다음으로 유해조류의 적응을 방지하기 위한 기존 유해조류 퇴치 기법들을 조사했지만, 우리가 찾아본 결과로는 조류 퇴치 연구 중에서 적응을 다루고 있는 연구는 없었다. 단지 몇몇 조류 퇴치 기법 연구들에서 적응을 막기 위한 시도 정도로만 소개된다[4-23]. 이러한 연구들을 통해 새로운 퇴치 위협 수단들이 지속적으로 연구되고 있지만 여전히 유해조류의 적응으로 인해 시간이 흐른 뒤에 효과가 상실되는 문제가 있다. 이러한 문제를 해결하기 위해서는 유해조류의 반응을 학습하여 적응을 판단하고, 적응을 시도할 경우 새로운 낯선 위협을 통해 적응하기 힘든 형태의 위협을 가해야 한다.

우리는 관점을 달리하여 적응을 방지하기 위해서 새로운 퇴치 수단이 아니라 기존에 사용되고 있는 수단을 활용하여 적응을 방지하는 것을 목표로 한다. 기존 조류 퇴치 기법들은 소리를 가장 많이 사용하고 있는데, 이는 소리가 다양한 종류와 넓은 영역에서 조류에게 위협을 줄 수 있는 특징을 가지고 있기 때문이다. 따라서 우리는 이러한 소리 위협을 활용하여 유해조류가 가장 적응 할 수 없는 방식으로 재생하고자 한다.

유해조류에게 가장 적응 할 수 없는 방식으로 소리 위협을 재생하기 위해서는 유해조류의 적응을 판단해야 하는데 이는 매우 어려운 일이다. 우리가 찾아본 바로는 위협 소리에 대한 유해조류의 적응도를 판단 할 수 있는 기준이나 방법에 대한 연구는 시도되지 않았다. 먼저 유해조류를 학습하기 위해 최신 기술인 딥러닝을 사용하는 것은 학습 기준에 맞춘 많은 양의 과거 데이터가 필요하다. 또한 유해조류는 종과 개체별 성격에 따라 같은 위협에도 다르게 반응할 수 있으며, 심지어 서식지 환경에 따라 같은 위협에도 다른 반응을 보일 수 있다. 예를 들면, 한 조류의 서식지가 공사장 근처일 경우, 숲에 서식하는 같은 종의 조류보다 폭발음에 덜 민감하게 반응한다. 이러한 특성을 고려할 수 있도록 모든 환경에서 모든 종에 대한 데이터를 수집하여 딥러닝 모델을 만드는 것은 사실상 불가능하다.

따라서 우리는 유해조류의 적응을 판단하기 위해서 유해조류의 행동을 머신 러닝(Machine Learning) 기법 중 강화학습(Reinforcement Learning)과

몬테카를로(Monte Carlo) 이론을 활용하여 학습한다. 강화 학습은 사람이 학습하는 과정과 유사하게 환경에서 에이전트가 행동을 하고, 행동에 대해 보상을 통해 행동을 평가하며, 이 정책에 따라 경험을 통해 가장 좋은 행동을 찾아내는 기법이다 [23]. 몬테카를로 접근법은 이러한 에이전트의 행동에 대한 보상 값들을 지속해서 누적하여 학습하는 것이 아니라 오직 현재 발생한 실제 경험만으로 평가할 수 있도록 수행하는 기법이다 [24][25]. 따라서 우리는 유해조류의 불규칙한 개체별 성격과 다양한 환경에서의 반응을 학습하고 적응을 판단하기 위해 Anti-adaptation Wild Birds Repelling(AWBR) 알고리즘을 제안한다.

본 논문에서 우리는 Faster R-CNN을 활용한 비전 기반 유해조류 탐지 기법인 WBBC와 위협에 대한 유해조류의 반응을 학습하고 적응을 방지하는 퇴치 기법인 AWBR 제안한다. WBBC 알고리즘은 Faster R-CNN을 사용하여 조류를 행동에 따라 구분하는 것으로 과수원과 같이 복잡한 농업 환경에서 탐지 정확도를 개선한다. AWBR 알고리즘은 Long-term과 Short-term 적응이라는 두 가지 시점을 사용하여 유해조류의 적응을 판단하며, 강화학습을 통해 유해조류의 행동을 학습하고 가장 적응하기 힘든 형태의 위협 소리를 제공하는 것으로 적응을 방지한다.

본 논문의 나머지 부분은 다음과 같이 구성된다. 섹션 2에서는 야생 조류 탐지와 퇴치 그리고 딥 러닝에 대한 관련 논문에 대해 소개한다. 섹션 3은 야생 조류 탐지 기법 WBBC 알고리즘과 퇴치 기법 AWBR 알고리즘을 자세하게 다룬다. 섹션 4는 실험을 통해 WBBC와 AWBR의 성능을 평가한다. 마지막으로 섹션 5는 결론을 내린다.

제2장 관련 연구

제1절 조류 탐지 기법

이 섹션에서는 초음파, 레이더, 마이크, 그리고 비전 센서와 같은 다양한 센서를 활용하여 조류 탐지를 시도한 연구들을 소개한다.

초음파 센서를 활용한 조류 탐지 연구는 근거리 탐지를 목적으로 사용되어졌다. Qu Fang은 야생 조류로부터 전신주를 보호하기 위해 초음파 센서를 사용한 탐지 기술을 제안하였다[13]. 초음파 센서는 과수원과 같은 우리가 탐지를 목표로 하는 환경에서는 탐지 범위가 좁고 탐지한 물체를 인식할 수 없어서 사용하기 어렵다.

레이더 센서를 활용한 탐지 연구들은 영역이 넓고 개방된 환경에서 사용되어졌다. J.R. Moon은 레이더를 통해 조류를 탐지하고, 조류의 특징을 추출하여 비행기와 구분하는 기법을 제안하였다[14]. Jianmin Song은 선형 중립 회귀법을 사용하여 단일 레이더에서 조류의 정보를 추출하는 방법을 제안하였다[15]. 이러한 레이더 기반 탐지 기법은 하늘과 바다와 같은 개방된 환경에서 효율적이지만 초음파 센서와 같은 이유로 물체로 인식할 수 없는 한계가 있다.

Dan Stowell은 마이크 센서를 사용하여 넓고 장애물이 많은 큰 숲에서 야생 조류를 소리를 통해 탐지하고 분류하는 연구를 수행하였다[16]. 대부분의 마이크 센서를 사용한 야생 조류 탐지 기법은 소리를 통해 생물학적 특성 모니터링을 위해 사용되며, 조류의 침입 탐지를 목적으로 할 경우 소리를 내기 전까지 탐지할 수 없기 때문에 성능이 떨어지는 문제가 있다.

비전 센서는 물체를 탐지하기 위해서 다른 센서에 비해 상대적으로 센싱된 데이터를 분석하는데 많은 컴퓨팅 연산을 요구하지만, 탐지된 물체가 무엇인지 인식할 수 있다는 장점이 있다. 이러한 장점 때문에 다양한 분야에서 물체를 탐지하고 인식하는 연구가 시도되어지고 있으며, 조류 탐지 분야 또한 다양한 기법들이 연구되어지고 있다. Marini는 SIFT 알고리즘을 활용하여 조류를 탐지하였으며, 마이크 센서를 통해 종을 분류할 수 있는 기법

을 제안하였다[17]. Debajyoti Karmaker는 야생 조류 이미지의 HOG 그래프에서 SVM과 CNN을 사용하여 종을 분류하는 방법을 제안했다[18]. Yan Li는 Optical Flow 알고리즘을 활용하여 움직이는 다수의 야생 조류를 배경에서 구분하는 탐지 기법을 제안하였다[19]. Ce Li는 Faster R-CNN 알고리즘을 활용하여 저해상도 이미지에서 조류 분류의 신뢰성을 개선하는 연구를 제안했다[20]. Akito Takeki는 CNN 기반의 완전 컨볼 루션 네트워크 및 슈퍼 픽셀 기반 시맨틱 세그멘테이션 방법으로 풍력 발전소의 터빈에 접근하는 야생 조류 탐지를 시도하였다[21]. Xiao-yan Zhang은 Markov Chain Monte Carlo 필터를 사용하여 배경에서 야생 조류를 탐지하였다[22]. Shuman Tian은 Markov 모델을 사용하여 야생 조류의 비행 패턴 모델을 생성하고 Faster R-CNN을 사용하여 야생 조류를 실시간으로 탐지하였다[23].

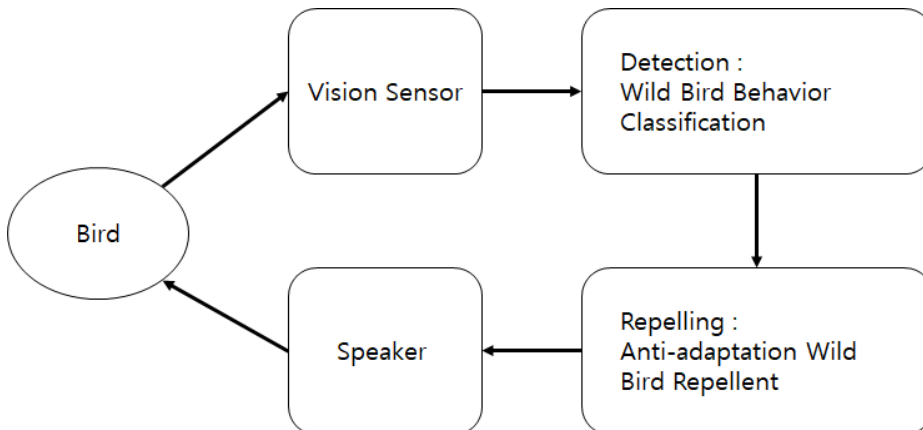
이러한 이미지 처리 및 딥러닝 알고리즘을 통한 조류 탐지 연구들이 시도 되어졌음에도 불구하고 과수원과 같이 복잡한 실제 환경에서 유해조류를 탐지하는 것은 여전히 어려운 일이다. 앞서 언급한 것처럼 이미지 처리 알고리즘은 각 경우에 객체와 환경을 사람이 개입하여 정의해야하는데, 조류와 같은 생물은 움직임에 따른 외형 변화 전체의 특징을 모두 추출해야만 탐지가 되는 어려움이 있으며, 딥러닝 알고리즘의 경우는 네트워크 구조가 조류의 수많은 모습을 학습함에 따라 발생하는 오버피팅 문제로 인해 탐지 정확도가 떨어지는 문제가 있다.

제2절 유해조류 퇴치 기법

이 섹션에서는 유해조류 퇴치 기법의 관련 연구를 소개한다. Turner PR은 바람에 지속적으로 흔들리는 연으로 시각적인 위협을 할 수 있는 퇴치 장치를 제안하였다[4]. 이 방법은 바람에 영향을 받으며 유해조류는 설치 후 시간이 지남에 따라 연을 하나의 환경으로 학습하고 빠르게 적응 할 수 있다. Lee S는 레이저를 통해 야생 조류를 위협하여 제어하는 장치를 제안했다[5]. 이 방법은 야생 조류가 적응하기 어렵지만 레이저를 눈에 정확하게 맞추어야만 효과가 있기 때문에 퇴치 범위가 제한적이기 때문에 과수원과 같은 환경에서는 사용이 어려운 문제가 있다. Simon G가 소개한 것처럼 전체 농장을 그물로 덮는 방법도 있다[6]. 하지만 자연 환경에 노출되는 그물은 부식이 빠르기 때문에 매년 교체해야하기 때문에 비싼 유지 비용을 요구한다. 화학적 약품을 방법을 통한 다양한 퇴치하는 기법들 또한 제안되었다[7-10]. 화학적 약품을 사용한 기법들은 날씨에 따라 약품이 적절하게 유지되지 않으면 효과가 크게 떨어지는 문제가 있다. Ma DF는 휘파람 소리가 발생하는 장치로 전신주를 유해조류로부터 보호하는 연구를 제안했다[11]. Zhao Z는 유해조류 퇴치 위협 수단으로 천적 소리를 사용하였다[12]. 이렇게 레이저, 소리, 그리고 시각적인 수단과 같이 새로운 퇴치 기법들이 지속적으로 제안되었지만 유해조류는 여전히 퇴치 기법들을 학습하고 적응하고 있다.

제3장 유해조류의 적응을 방지하기 위한 딥러닝과

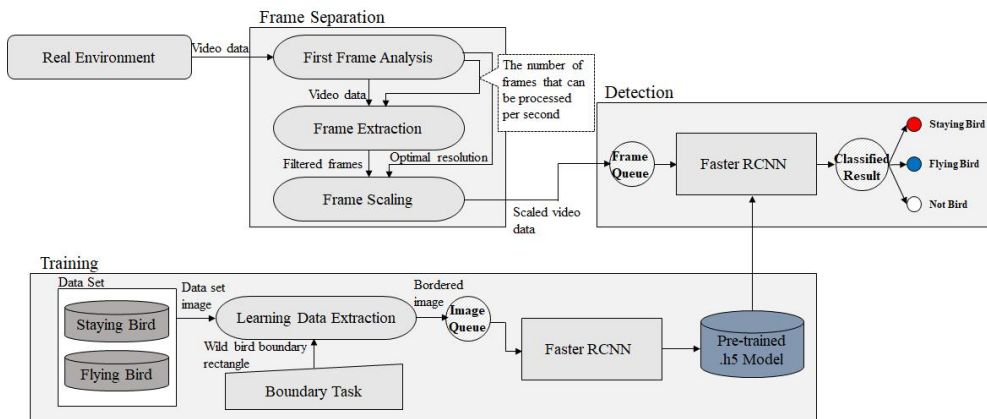
강화학습을 활용한 퇴치 시스템



<그림 4> 유해조류의 적응을 방지하기 위한 딥러닝과 강화학습을 활용한 퇴치 시스템의 구성.

본 장에서는 유해조류의 적응을 방지하기 위한 딥러닝과 강화학습을 활용한 퇴치 시스템을 다룬다. 그림 4와 같이 본 시스템은 비전센서를 통해 유해조류를 탐지할 수 있는 WBBC 알고리즘과 소리 위협을 적응할 수 없는 형태로 제공하는 AWBR 알고리즘으로 구성되어 있다.

제1절 탐지 : Wild Bird Behavior Classification 알고리즘



<그림 5> Wild Bird Behavior Classification(WBBC) 알고리즘 구조.

본 절에서 유해조류 탐지를 위한 Wild Bird Behavior Classification 알고리즘에 대해 설명한다. 우리는 과수원과 같이 복잡한 환경에서도 유해조류를 정확하게 탐지하기 위해서 딥러닝 기법인 Faster R-CNN 알고리즘을 사용한다. 또한 딥러닝 기법에서 학습시 발생하는 오버피팅 문제를 유해조류의 행동에 따라 데이터를 정규화하는 과정을 통해서 정확도를 개선한다.

WBBC 알고리즘은 야생 조류 학습을 위한 Training 프로세스와 탐지를 위한 Detection 프로세스, 그리고 추가적으로 침입하는 야생 조류를 실시간으로 탐지하기 위해 실시간 비디오 데이터를 처리하는 Frame Separation 프로세스로 구성된다. 알고리즘의 전체 구성은 그림 5에서 볼 수 있다.

1. Frame Separation

WBBC 알고리즘의 첫 번째 모듈인 Frame Separation 모듈은 알고리즘이 동작하는 환경에 따라 데이터의 해상도를 조절하여 최적의 상태로 동작할 수 있도록 전처리를 한다. 유해조류의 침입을 탐지하기 위해서 이 탐지 알고리즘은 실시간으로 동작해야한다. 하지만 Faster R-CNN은 입력되는 데이터의 크기가 클수록 연산량이 선형으로 상승하기 때문에, 우리는 이 모듈을 통해서 실시간으로 동작할 수 있도록 입력 데이터를 조정한다. 예를 들면, WBBC 알고리즘이 동작하는 환경의 성능이 낮아 현재 입력되는 해상도의 비디오 데이터를 초당 하나 이상의 프레임을 처리할 수 없을 경우, 현재 시점에 처리하는 프레임은 이미 과거 시점의 데이터로 실시간 탐지를 할 수 없는 문제가 발생한다. 따라서 유해조류의 침입을 탐지하기 위해 실시간으로 동작해야하는 상황에서는 해상도를 알고리즘이 동작하는 환경에 맞추는 것은 매우 중요하다.

WBBC 알고리즘 동작시, Frame Analysis 부분에서 처음 입력되는 비디오 데이터 프레임은 224p, 480p, 720p로 정의되어있는 프리셋 해상도로 각각 변환된다. 그리고 첫 프레임을 변환한 각각의 해상도에서 유해조류를 탐지를 위해 필요한 연산 시간을 측정한다. 해상도가 낮을 경우 탐지 정확도가 떨어지기 때문에, 우리는 초당 한 개 이상의 프레임을 처리 할 수 있는 가장 높은 해상도 모드를 프리셋 중에 선택한다.

다음 Frame Extraction 모듈은 선택된 해상도 모드에서 초당 처리 가능한 프레임의 숫자를 계산하며, 실시간으로 입력되는 비디오 데이터의 프레임에서 동작하는 환경에서 초당 처리 가능한 숫자의 프레임을 추출한다.

Frame Scaling 모듈은 Frame Analysis와 Frame Extraction 모듈의 결과를 기반으로 추출된 프레임들을 선택된 최적의 해상도로 조정하여, Detection 프로세스의 Frame Queue에 입력한다.

전체 프로세스는 알고리즘 1에서 볼 수 있으며, Frame Separation 프로세스는 입력되는 비전 센서 혹은 비디오 데이터의 해상도와 초당 프레임 수에 관계없이 실시간으로 유해조류 침입 탐지를 가능하게 한다. 하지만 가장 낮은 프리셋의 해상도에서 초당 1 프레임 이하의 처리속도를 가질 경우 탐

지 정확도가 떨어질 수 있다.

Algorithm1 : Frame Separation

```

1  Input :   Video data (Camera or Video file)
2  Output :  Frames of numbers that    can be processed per
              second, scaled by mode
3  IF gets first frame :
4  Gets width, height and Frame Per Second information in first
    frame;
5  Calculates the mode and input frames per second through the
    time of one operation in Detection each 3mode, resolution mode is
    224p, 480p, and 720p;
6  Sets the mode according to input frames per second, input
    frames per second is the maximum value    for which the
    computation time of one frame is less than 1.
7  While do get frames per second:
8  IF last frame or frame is none : BREAK
9  ELSE:
10 Filters frames by the input frames per second
11 Scales by the selected mode;
12 Input to Detection

```

2. Training

Training은 Faster R-CNN을 사용하여 유해조류를 행동에 따라 분류할 수 있도록 학습하는 핵심 프로세스이다. 이 프로세스의 목표는 유해조류 탐지를 위해 사전 훈련된 딥러닝 데이터 모델을 구축하는 것이다. 모델을 구축하려면 Training 프로세스를 통해 유해조류 이미지에서 유해조류로 분류 가능한 특징들을 수집해야한다.

우리는 초기에 Faster R-CNN을 사용하여 유해조류를 학습하기 위해서 CUB-200 데이터 세트를 사용했다. CUB-200은 조류 200종에 대해서 종별로 이미지를 수집한 데이터 세트이다[26]. 그리고 구글에서 임의의 유해조류 이미지와 동영상을 사용하여 테스트한 결과, 탐지 정확도가 70%이하로 떨어지는 문제가 발생하였다. 탐지에 실패한 이미지들에서 우리는 다음과 같은 유해조류의 특성을 도출하였다. 첫 번째는, 유해조류의 조류는 크기, 부리, 색, 그리고 다리와 같이 다양한 외형을 가지며, 같은 종이라도 서식지에 따라 외형이 다를 수 있는 외형의 다양성을 가지고 있다. 두 번째는, 야생 조류는 자동차와 같이 각도에 따라 고정된 어떤 형태를 갖는 것이 아닌 앉아 있거나 비행하는 행동에 따라 외형이 크게 변화한다는 것이다. 이러한 요인들은 딥 러닝에서 너무 많은 특징들을 고려하다가 오히려 분류를 정확도가 떨어지는 오버피팅 문제의 원인이다.


우리는 다양한 유해조류를 탐지하기 위해서 200종으로 분류된 조류 데이터 세트의 일부와 구글에서 검색된 조류 이미지를 유해조류라는 하나의 카테고리로 묶고, 유해조류의 외형을 행동에 따라 Staying Bird과 Flying Bird으로 수작업을 통해 다시 분류하였다. 그리고 우리가 새로 분류한 유해조류 데이터 세트를 사용하여 Training 프로세스는 앉아 있는 야생 조류 Staying Bird과 비행하는 야생 조류 Flying Bird 그리고 Not Bird로 분류 할 수 있는 모델을 생성하였다.

Learning Data Extraction 모듈은 데이터 세트에서 학습에 사용할 이미지들을 선택하며, 선택된 이미지는 Boundary Task 모듈에서 수작업으로 학습을 위해 객체가 있는 영역에 대한 정보가 추가되어진다. 그리고 객체가 있는 영역에 대한 정보가 추가된 유해조류 이미지들은 Image Queue에 입력

된다.

다음으로 우리는 WBBC 알고리즘은 학습을 하기 위해서 VGG-16 네트워크 모델을 사용하였다. 과수원과 같은 복잡한 실제 환경은 과수나무의 가지, 잎, 열매, 그리고 다양한 농기구들로 환경이 구성될 수 있다. 따라서 이런 복잡한 환경에서 유해조류를 구분하기 위해서는 깊은 구조의 네트워크 모델이 필요하다. VGG 모델은 깊은 구조를 가진 다양한 딥 러닝 모델 중에서 높은 정확도로 객체를 분류하기 위한 좋은 후보 중 하나로 잘 알려져 있다[27]. 따라서 우리는 VGG-16 모델의 구조를 사용하여 신경망을 구성하였다. 그림 6는 해상도 프리셋 중 224p 입력 프레임의 네트워크 모델이다. 각 단계는 컨볼루션 계층(Convolution), 활성화 함수(ReLU), 풀링 계층(Max Pooling)으로 구성되며, 최종적으로 유해조류를 Staying Bird, Flying Bird, Not Bird로 구분하기 위해 완전 연결 계층(Fully connected)과 소프트맥스 계층(SoftMax)에 연결된다.

Training 프로세스는 학습을 통해 가중치 데이터를 생성하며, 이 데이터를 모델이라고 한다. 가중치 모델은 .h5 확장자로 저장되며, 우리는 4장 1.3 절에서 야생 조류를 행동에 따라 분류하여 탐지하는 것에 대한 성능을 검증한다.



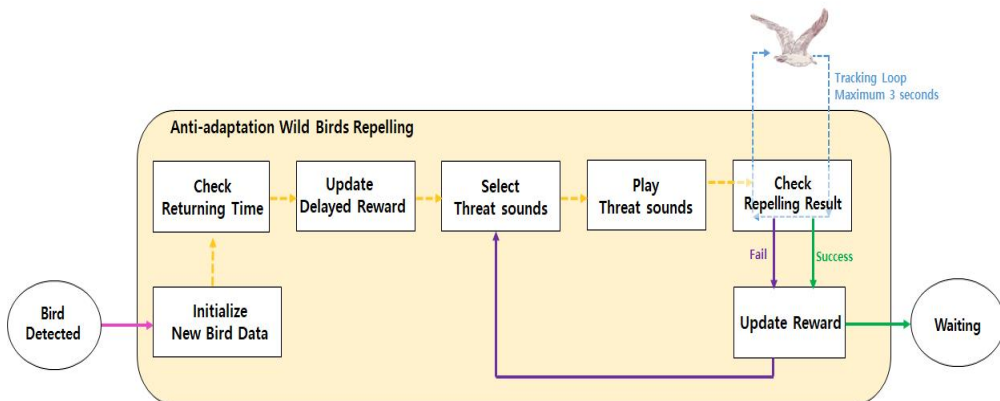
<그림 6> VGG-16 모델을 사용한 224p 해상도 모드의 네트워크 모델 구조.

3. Detection

Detection 프로세스는 Frame Separation 프로세스에서 입력된 프레임과 Training 프로세스에서 생성된 가중치 모델을 사용하여 유해조류를 탐지한다. 보다 구체적으로, Detection 프로세스는 Frame Queue에 입력되어 있는 프레임들을 읽고, 읽어온 프레임은 Training 프로세스에서 생성한 모델을 통해서 탐지를 한다. 이 때 탐지 결과는 Flying Bird, Staying Bird, 그리고 Not Bird로 분류되며, 분류 확률과 유해조류의 위치로 나타난다. Not Bird는 결과로 표시 하지 않는다.

제2절 퇴치 : Anti-adaptation Wild Birds Repelling 알고리즘

1. Framework



<그림 7> Anti-adaptation Wild Birds Repelling(AWBR) 알고리즘의 구조. 유해조류가 침입한 상황에 대응하는 시나리오에 따른 프로세스로 구성되어 있으며, 본 그림에서 원형은 상황을 의미하며, 사각형은 프로세스를 의미한다.

본 절에서는 Anti-adaptation Wild Birds Repelling(AWBR) 알고리즘의 프레임 워크를 소개한다. AWBR 알고리즘은 유해조류의 반응을 학습하여 적응에 대해 판단하고, 가장 적응 할 수 없는 형태로 위협 소리를 재생한다. 그림 7은 Initialize New Bird Data, Check Returning Time, Select Treat sounds, Check Repelling Result, 그리고 Update Reward 프로세스의 구성을 보여준다.

AWBR 알고리즘은 유해조류가 탐지된 경우에 동작한다. 첫 번째 단계로 Initialize New Bird Data 프로세스는 탐지된 유해조류가 처음 탐지된 경우를 의미한다. 이 때, 탐지된 야생 조류는 BirdType으로 분류되며, 이 BirdType 값은 조류가 탐지 되지 않은 경우에는 0, 유해조류가 탐지된 경우 분류되는 형식에 따라 1-n의 값을 가진다. 추가적으로 BirdType은 종과 조류 수를 고려한다. 예를 들어, 동일한 종의 유해조류 한 마리 침입과 여러 마리의 침입은 다른 유형으로 간주한다. 유해조류 데이터 B에 탐지된 BirdType이 없는 경우, 식 (1)과 같이 새로운 BirdType에 대한 b가 생성된다.

$$B = \{b_{BirdType1}, b_{BirdType2}, b_{BirdType3}, \dots, b_{BirdType n}\} \quad (1)$$

예를 들어 탐지된 유해조류가 BirdType1일 경우, b 는 식 (2)와 같이 BirdType1에 대한 Returning Time, Enduring Time, Reward Table로 구성된다. Reward Table은 사용가능한 퇴치 위협 소리에 대한 보상에 대한 정보가 저장되는 테이블이다. 우리는 유해조류를 학습하기 위해서 강화학습 이론을 활용한다. 따라서 강화학습에서의 행동은 본 기법에서 유해조류 퇴치를 위한 위협 소리의 조합을 의미하고, 보상은 위협 소리의 조합에 대한 유해조류의 반응에 대한 평가를 의미한다. 또한 위협 소리에 대한 유해조류의 반응은 다양한 변수들로 인해서 소리에 대한 위협 수준의 예측이 어렵다. 따라서 우리는 모델을 생성하지 않고 오직 발생한 상황만을 학습하며, 실제 RewardTable은 경험에 따른 값만 업데이트 된다. 초기에는 어떤 소리가 가장 좋을지는 알 수 없기 때문에, 모든 행동에 대한 RewardTable의 초기 보상은 0.0에서 3.0사이의 값으로 임의로 초기화한다. 여기에서 3.0의 임계값은 EnduringTime과 연결되는 부분이다. 이 초기화 정책은 AWBR 알고리즘이 강화학습에서 발생하는 Exploit and Exploration 이슈를 고려 할 수 있게 하며 너무 Exploit 하지 않도록 도와준다[23]. 따라서 AWBR 알고리즘의 동작 초기 보상 값은 유효하지 않을 수 있지만, 알고리즘이 동작하면서 유해조류의 침입을 학습하고 실제 경험에 기반하는 유효한 보상 값으로 변경된다.

$$b_{BirdType1} = \{Returning Time_{BirdType1}, Enduring Time_{BirdType1}, Reward Table_{BirdType1}\} \quad (2)$$

Check Returning Time 프로세스는 유해조류가 재침입하는 경우에 재침입하기 위해 소요된 시간을 확인한다. 우리는 유해조류의 적응을 학습하기 위해 두 가지 중요한 매개 변수를 사용합니다. Returning Time은 그 중 하나이며, Long-term 적응을 판단하기 위해 유지 한다. Long-term 적응이란 유해조류가 탐지 영역에서 퇴치된 이후 다시 침입하는 것과 같이 긴 시간을 가지고 학습하는 것을 의미한다. 따라서 Returning Time은 식 (3)과 같이

유해조류가 이전 침입한 시간에서 현재 침입한 시간의 감산을 통해서 재침입 하는데 걸린 시간을 나타낸다.

$$Returning Time_t = Current Invasion Time - Previous Invasion Time \quad (3)$$

Update Delayed Reward 프로세스는 Returning Trend에 따라 이미 보상된 값을 조정한다. Returning Trend는 식 (4)에 표시된 것처럼 유해조류의 Long-term 적응을 결정한다. Returning Trend의 감소는 사용된 퇴치 위협 소리의 위협이 감소되고 있으며, 유해조류가 재침입을 하면서 점차적으로 적응하고 있음을 의미한다. Returning Trend의 증가는 사용된 퇴치 위협 소리의 위협이 증가되고 있으며, 유해조류가 적응에 실패하는 것을 의미한다. 우리는 강한 위협 소리라도 반복해서 접할 경우 적응하는 유해조류의 특성에 따라서 적응하는 특성을 고려하여, Returning Trend가 감소 할 때 이전에 재생된 위협 퇴치 소리에 대한 보상을 줄이기만 한다.

$$Returning Trend_t = Returning Time_t - Returning Time_{t-1} \quad (4)$$

Select Threat sounds 프로세스는 식 (5)처럼 탐지된 BirdType의 Reward Table에서 현재 상태에서 가장 높은 보상 값을 가지고 있는 위협 소리 조합을 선택한다. Reward Table에 가장 큰 보상 값이 두개 이상일 경우 순차적으로 선택한다. 다음으로, Play Threat sounds 단계는 이전 단계에서 선택된 위협 소리를 재생한다.

$$Threat Sound(BirdType) = \underset{a \in A}{\operatorname{argmax}} Reward Table(BirdType, a) \quad (5)$$

Check Repelling Result 프로세스는 위협 소리가 재생되는 동안 유해조류를 BirdType 값을 추적하는 것을 통해 유해조류를 모니터링한다. 여기에서 유해조류의 적응을 판단하기 위한 다른 매개 변수인 Enduring Time을 계산하며, 이 매개 변수는 Short-term 적응을 결정한다. Short-term 적응이

란 위협 소리를 재생했을 때 유해조류가 퇴치되지 않는 상황과 같은 짧은 기간 동안 적응하는 상태를 의미한다. 이 프로세스는 위협 소리의 재생한 시간부터 유해조류가 퇴치된 시간을 측정하며, 최대 3 초 이내로 측정한다. 유해조류가 3 초 이상 위협 소리에 저항하는 경우 AWBR 알고리즘은 현재 사용한 퇴치 위협 소리로는 퇴치가 불가능하며, 유해조류가 Short-term 적응에 성공한 것으로 판단한다. 우리는 유해조류를 학습하기 위해 다양한 실험을 수행하였고, 경험적으로 유해조류가 3초 이상 위협 소리에 견딜 경우 먹이를 먹는다는 사실에 기반하여 임계값을 설정하였다. 이 측정 시간은 식 (6)에 따라 구할 수 있다.

$$Enduring Time_t = Threat Sound Played Time - Repelled Time \quad (6)$$

Update Reward 프로세스는 Check Repelling Result 프로세스의 결과에 따라서 사용된 행동, 즉 유해조류 퇴치에 사용한 퇴치 소리의 조합에 대해서 보상한다. 이 프로세스에서는 행동에 대한 보상과 사용되지 않은 행동들에 대해 고려한다. AWBR 알고리즘은 유해조류가 3 초 이내에 격퇴되면 위협 소리가 효과적인 것으로 판단하며, Reward Table에서 이 행동에 대한 보상 값을 퇴치한 시간에 비례하여 증가시킨다. 이 보상 값은 Returning Time 매개 변수와 유사한 식(7)의 Enduring Trend에 따라 식 (8)과 같이 적용할 수 있다. Enduring Trend가 양수일 경우 유해조류는 현재 사용된 퇴치 소리 조합에 Short-term 적응하고 있음을 의미한다. 반대로, 음수 값은 유해조류의 Short-term 적응 방지에 성공한 것을 의미한다. 추가적으로 유해조류 퇴치 환경은 동일한 행동에 대해 동일한 보상을 기대할 수 없는 확률적 환경이다. 따라서 우리는 Reward Table에 행동에 대한 보상 값을 식 (7), (8)과 같이 적용하는 것을 통해 위협 소리에 대한 유해조류의 반응을 학습 하였다.

$$Enduring Trend_t = Enduring Time_t - Enduring Time_{t-1} \quad (7)$$

$$Reward Table(BirdType, Seleted Action) - Reward Table(BirdType, Selected Action) - Enduring Trend_t \quad (8)$$

우리의 접근 방식은 유해조류가 특정 위협 소리를 반복해서들을 때 학습한다고 가정한다. 따라서 보상 테이블에 값을 업데이트 할 때, 사용되지 않은 행동의 보상 값은 식 (9)와 같이 업데이트된다. 이 정책은 유해조류 퇴치 효과가 가장 높은 위협 사운드를 반복적으로 재생하는 상황을 방지하고 AWBR 알고리즘이 행동에 대한 선택을 보다 탐색적으로 할 수 있게 만든다.

$$\begin{aligned} & \text{Reward Table}(\text{BirdType}, \text{All actions without Threat Sound}) \\ & - \text{Reward Table}(\text{BirdType}, \text{All actions without Threat sound}) \\ & + 0.1 \end{aligned} \quad (9)$$

퇴치 소리가 재생되고 3 초 동안 퇴치가 실패할 경우, 이 프로세스는 실패한 행동에 대해 -3 값을 업데이트한다. 이후 Select Threat sounds 프로세스를 다시 시작한다. 이 과정들의 반복을 통해 AWBR 알고리즘은 강화 학습의 몬테카를로 접근법과 같은 방법을 활용하여 야생 조류의 적응을 방지할 수 있다. 알고리즘 2는 프로세스들의 자세한 흐름을 나타낸다.


Algorithm 2. Anti-adaptation Wild Bird Repelling Algorithm

```

1 Initialize:
2   Returning Time = {Returning Time1, ..., Returning Timen} is a list of history
3   Enduring Time = {Enduring Time1, ..., Enduring Timen} is a list of history
4   Reward Table = {reward[0][0], ..., reward[count of threat][Volume level]} is a set of reward
5   B = < Returning Time, Enduring Time, Reward Table > is a bird information for learning
6
7 Begin :
8 Loop
9   BirdType ← Detection and Classification.
10  If BirdType = 0 then
11    Goto line 9
12  EndIf
13  If new BirdType then
14    bBirdType ← Initialize New Bird Data
15  EndIf
16  If Returning Trend is increased in the Check Returning Time then,
17    rewardlast action ← rewardlast action * 0.5 //Delayed Reward Update
18  EndIf
19  Loop until the time when wild birds are repelled.
20    Selected Action ← Select Threat Sounds (bBirdType.rewardTable)
21    Loop Play Threat Sounds(Selected Action) until maximum 3 Second
22      Enduring Time ← Count millisecond
23      If wild birds have repelled in Detection and Classification Then
24        Break
25      EndIf
26    EndLoop
27    //Update Reward follow :
28    bBirdType.Reward Table ← RewardSelected Action - Enduring Trendt
29    bBirdType.Enduring Time ← Enduring Timet
30    bBirdType.RewardTable ← applied + 0.1 correction to all unused action
31  EndLoop
32 EndLoop
33 End
34

```


2. 강화 학습 이론을 적용하기 위한 환경 구성



<그림 8> AWBR 알고리즘에서 *Situation* S_n 의 구성. S_n 은 야생 조류의 n 번째 침입을 의미한다.

본 절에서는 AWBR 알고리즘의 환경을 강화학습의 에이전트(Agent), 환경(Environment), 행동(Action), 보상(Reward) 그리고 상황(Situation)과 같은 강화 학습을 적용하기 위한 환경으로 그림 8과 같이 정의한다.

AWBR 알고리즘에서 환경은 에이전트가 유해조류를 탐지 할 수 있는 전체를 의미한다. 상황은 에이전트가 환경에서 유해조류의 침입을 탐지한 상황을 의미하며, AWBR 알고리즘이 동작한 시간 t_1 에서 t_n 사이에서 발생하므로, 그림 8의 두 번째 그림과 같이 $s_n t_n$ 으로 표현 할 수 있다. 에이전트는 보상에 따라 가장 좋은 행동을 선택하여 유해조류를 퇴치한다. 본 시스템에서 행동은 야생 조류 퇴치를 위한 소리의 조합이며, 하나의 위협 소리는 3가지의 볼륨으로 나누어 3가지의 행동으로 구성된다. 각 음량 레벨은 스피커 최대 음량의 100%, 70% 그리고 30%으로, 실험을 통해 경험적으로 이 수치들은 결정되었다. 에이전트가 행동을 취한 후, Reward Table의 보상들은 Long-term과 Short-term 적응 판단 정책에 따라서 조정된다. 이 경우 상황 s_1 인 경우 행동은 a_1 그리고 보상은 r_2 로 나타낸다. 최종적으로 상황 s , 행동 a , 보상 r 은 그림 8과 같이 강화 학습의 구조로 구성된다.

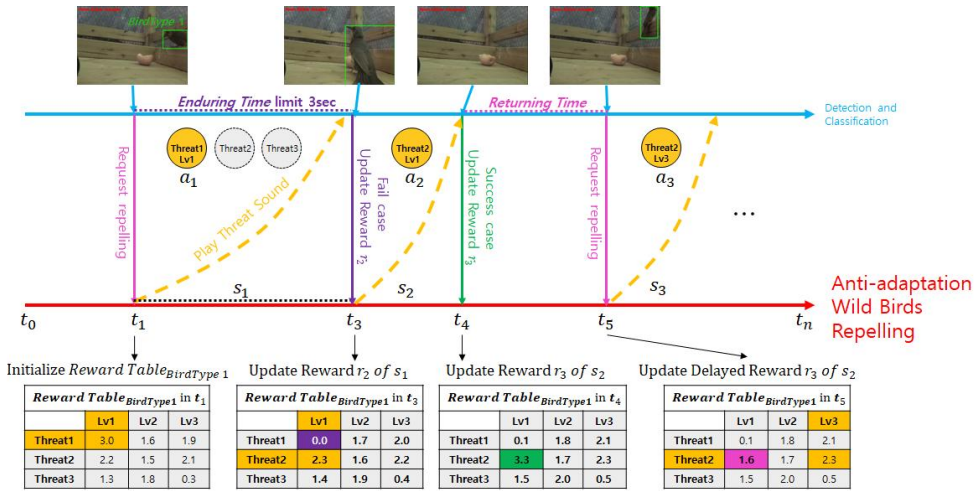


<그림 9> 유해조류의 적응 판단 기준 Long-term과 Short-term.

그리고 강화학습 구조로 구성된 본 시스템의 환경에서 적응의 판단 기준인 Long-term과 Short-term은 그림 9와 같이 표현된다.

우리는 유해조류 퇴치 환경을 강화학습과 같이 에이전트가 환경에서 수행하는 행동 그리고 행동에 따른 보상 프로세스를 통해 유해조류의 행동을 학습하고 적응을 방지할 수 있는 기법을 구현하였다.

3. AWBR 알고리즘의 구현



<그림 10> 구현된 AWBR 알고리즘의 동작 시나리오. 이 시나리오는 BirdType1로 구분된 유해조류가 침입하여 적응을 시도하는 것에 대응하는 AWBR 알고리즘의 시나리오이다. 각 화살표의 색과 모양은 그림 5의 화살표와 같은 의미를 내포한다.

본 절에서는 유해조류 침입 시나리오를 통해 AWBR 알고리즘의 구현에 대해 자세히 설명한다. 그림 9는 유해조류의 첫 번째 침입, 퇴치 실패 (Enduring Time을 초과한 경우), 퇴치 성공 및 재침입 (Returning Trend가 감소한 경우)과 같은 상황을 포함한다.


첫 번째 침입 및 퇴치 실패 사례는 그림 9의 s_1 이다. BirdType1이 먼저 탐지된 시간 t_1 에 $Reward Table_{BirdType1}$ 이 초기화되며, 시점 t_1 의 초기화된 테이블에서 가장 높은 보상값을 가진 행동은 $Threat_{Lv1}$ 이다. 따라서 액션 a_1 은 $Threat1_{Lv1}$ 이며 해당 소리 조합을 재생한다. Reward Table의 y 축은 위협 소리의 유형이며 x 축은 볼륨 레벨(Lv1이 가장 높은 볼륨)이다. 그림 9의 시나리오에 따라 시점 t_3 에서는 유해조류 BirdType1이 3 초에 동안 퇴치되지 않았다. 따라서 s_1 의 행동 a_1 의 보상 r_2 는 식 (8), (9)의 보상 정책에 따라 t_3 시점의 Reward Table과 같이 업데이트된다.

그림 9의 s_2 는 퇴치 성공 경우이며, 시점 t_3 에서 가장 높은 보상값을 가진 $Threat2_{Lv1}$ 가 행동 a_2 로 선택된다. 행동 a_2 를 수행 한 뒤, 유해조류의 퇴치가 성공하였고, 시점 t_4 에 보상 r_3 이 업데이트된다. 업데이트 결과는 t_4 시점의

Reward Table에서 확인할 수 있다.

상황 s_3 는 퇴치 후 재침입한 경우이며, 탐지된 유해조류 BirdType이 1이기 때문에 기존에 탐지했던 유해조류로 판단할 수 있다. 따라서 Long-term 적응 정책에 따라 식 (3), (4)를 적용하여 s_2 에 a_2 의 r_3 을 업데이트하며 결과는 시점 t_5 의 Reward Table에서 확인할 수 있다.

그림 11은 재침입 시나리오를 만들기 위해 구성한 폐쇄된 케이지 환경에서 구현된 AWBR 알고리즘의 동작을 보여 주며, 각 10 개의 이미지로 구성된 두 가지 실험 케이스를 보여준다. 그림 8의 녹색 상자는 유해조류가 감지되어 위협 소리가 재생되고 있음을 나타낸다. 케이지 환경 내부에 먹이는 유해조류 탐지 영역 내부에만 위치하기 때문에 유해조류가 생존을 위해 지속적으로 접근하는 것을 볼 수 있다.



<그림 11> 폐쇄적인 케이지 환경에서 구현된 AWBR 알고리즘의 동작의 스냅샷.

제4장 실험

제1절 WBBC 알고리즘의 성능 평가

1. 실험 환경

유해조류를 탐지하기 위한 학습 및 실험은 동일한 환경에서 수행되었다. 운영 체제는 Window 10, 프로세서는 Intel i7-4890 3.60GHz, 메모리는 32GB, GPU는 nVidia GTX 970 4GB에서 수행되었다. Faster R-CNN은 Python 3.6.5에서 Tensorflow 1.10.0, Keras 2.2.0, OpenCV 3.4.1, CUDA 9.0, cuDNN 9.0 라이브러리를 사용하여 구현하였다.

2. 데이터 세트

실험에 사용한 조류 데이터 세트는 총 19가지 조류로 구성하였다. 표 1은 훈련에 사용된 조류의 종을 나타내며, 구성한 조류 중에 몇몇은 이름을 알 수 없었기 때문에 Unknown으로 나타내었다. 데이터 세트는 구글 검색과 비디오 데이터에서 수집한 3850장의 이미지로 구성되었으며, 조류의 행동에 따라 Staying Bird와 Flying Bird로 정규화 작업을 수행 하였다.

<표 1> 학습에 사용한 야생조류의 종

	Species of Bird
1	Crow
2	BulBul
3	Magpie
4	Great Tit
5	Falcon
6	Auklet
7	Brewer Blackbird
8	Eastern Towhee
9	Chuck will Window
10	Mangrove Cuckoo

11	Slaty_backed Gull
12	Sayornis
13	Bank Swallow
14	Unknown name 1
15	Unknown name 2
16	Unknown name 3
17	Unknown name 4
18	Unknown name 5
19	Unknown name 6

3. 행동에 따른 조류 분류 기법의 성능 평가

이 실험에서는 행동에 따라 조류를 분류하여 탐지하는 기법의 성능을 평가한다. 우리는 야생 조류를 탐지하기 위해서 Wild Bird 또는 Not Bird 두 개의 상태가 아닌 Staying Bird, Flying Bird, Not Bird로 분류 한다. 행동에 탐지 성능을 평가하기 위해 위 두 가지 방법을 비교하였으며, Wild Bird 또는 Not Bird로 분류하는 모델이 Normal 모델이며, 행동에 따라 분류하는 모델이 Behavior Classification 모델이다. Normal 모델의 학습에는 조류로 구성된 2,695 개의 이미지를 사용하였다. Behavior Classification 모델의 학습은 Normal 모델의 학습에서 사용한 이미지를 Staying(1,524 images)과 Flying(1,171 images)으로 분류하여 사용하였다. 학습은 전체 데이터 세트의 70%인 2,695 개의 이미지로 수행하며 나머지 30%인 1,155 개 이미지로 검증하였다.

표 2는 검증 결과를 보여준다. Accuracy는 검증에 사용한 1,155개의 이미지를 정확하게 분류할 확률이다. Error Rate는 사용한 1,155개의 이미지에서 조류를 탐지 하지 못하는 Detection Failure 오류와 조류의 위치를 잘못 특정하는 Boundary Box Error가 발생한 비율을 의미한다.

Normal 모델은 1,155개 이미지 중 1,026개를 분류하여 Accuracy는 88.8%와 Error Rate는 32%의 결과를 보여준다. 다음으로 Behavior Classification 모델은 1,155 개의 이미지 중 1068을 감지하여 Accuracy 92.4%로 더 높은 정확도를 달성하였으며, 오류율 또한 12%로 Normal 모델

보다 개선된 결과를 보여준다.

이 결과는 조류의 행동에 따라 분류하여 학습시킬 경우, 야생 조류의 다양한 외형적인 특징 때문에 발생하는 딥 러닝의 오버피팅과 같은 문제를 개선할 수 있다는 것을 의미한다.

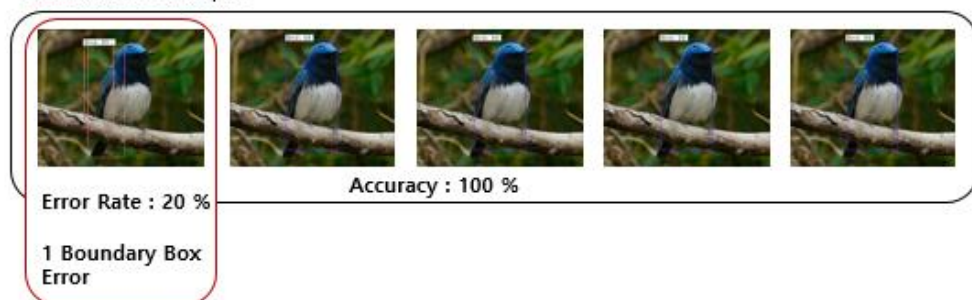
그림 13은 Normal과 Behavior Classification 모델의 검증 결과의 일부를 보여주며, 예제 1과 2는 Boundary Box Error와 개선된 결과를 보여준다. 예제 3과 4는 복잡한 환경에서 Detection Failure와 향상된 탐지 결과를 보여준다.

제안한 Behavior Classification 모델은 우리의 실험 환경에서 Normal 모델에 비해 Accuracy를 3.6% 향상시켰으며, Error Rate 또한 20% 감소된 것을 확인 할 수 있다. 그림 12은 5장의 이미지를 통해 유해조류 탐지 결과인 Accuracy와 Error Rate를 계산하는 예시를 보여준다. 5장의 이미지 모두에서 유해조류를 탐지 했으므로 100%의 Accuracy를 보여주지만, 1장의 이미지에서 Boundary Box Error가 발생했기 때문에 Error Rate가 20%이다.

<표 2> Behavior Classification과 Normal 모델의 검증 결과.

	Accuracy(%)	Error Rate(%)
Normal (Bird or Not)	88.8	32
Behavior Classification (Staying, Flying, Not Bird)	92.4	12

Evaluation Example



<그림 12> Accuracy와 Error Rate의 평가 예시.



<그림 13> Behavior Classification와 Normal 모델의 검증 결과물 비교.

4. WBBC 알고리즘의 성능 평가

이 실험에서 우리는 Behavior Classification 모델을 사용한 조류 탐지 기법인 WBBC 알고리즘과 기존의 비전 기반 조류 탐지 기법들의 비교를 통해 성능을 평가하였다. SIFT, SURF, Optical flow, HOG 알고리즘과 같은 기존의 특징 추출 방식의 물체 탐지 알고리즘을 성능 비교를 위해 구현하였다 [17-19]. 각 알고리즘의 구현 세부 사항은 다음과 같다.

4.1 SIFT 기법을 사용한 조류 탐지

Scale-Invariant Feature Transform(SIFT) 알고리즘은 이미지에서 사용 가능한 고유한 불변의 특징을 추출하고, 각 특징점을 일치시키는 방법으로 객체를 분류한다[28].

알고리즘 구현의 세부 사항은 다음과 같다:

- 1단계 : 비디오 데이터의 조류 이미지를 수동으로 캡처한다.
- 2단계 : 캡처한 야생 조류 이미지 세트에서 SIFT 알고리즘을 사용하여 이미지의 특징을 추출한다.
- 3단계 : 추출된 특징들을 저장한다.
- 4단계 : 비디오 데이터의 프레임들에서 SIFT 방식으로 추출된 특징들을 검색한다.



<그림 14> SIFT 알고리즘을 사용한 조류 탐지 결과.


4.2 SURF 기법을 사용한 조류 탐지

Speeded-Up Robust Features (SURF)는 스케일 및 회전 불변하는 특징

을 추출하는 알고리즘으로 SIFT 알고리즘의 오버헤드를 개선한 알고리즘이다[30].

알고리즘 구현의 세부사항은 다음과 같다:

- 1단계 : 비디오 데이터의 조류 이미지를 수동으로 캡처한다.
- 2단계 : 캡처한 조류 이미지 세트에서 SURF 알고리즘을 사용하여 이미지의 특징을 추출한다.
- 3단계 : 추출된 특징들을 저장한다.
- 4단계 : 비디오 데이터의 프레임들에서 SURF 방식으로 추출된 특징들을 검색한다.



<그림 15> SURF 알고리즘을 사용한 조류 탐지 결과.

4.3 Optical Flow 기법을 사용한 조류 탐지

Optical Flow는 비디오 데이터에서 프레임과 프레임 사이에서 픽셀의 상대적인 움직임으로 인해 배경에서 객체의 윤곽 및 움직임을 탐지 할 수 있는 알고리즘이다[30].

알고리즘 구현의 세부사항은 다음과 같다:

- 1단계 : 비디오 데이터의 프레임을 추출한다.
- 2단계 : 이미지를 흑백으로 변환하고 쓰레숄딩을 사용하여 프레임에서 윤곽을 추출한다.
- 3단계 : 수집된 프레임을 순차적으로 서로 비교한다. 예를들면 1번과 2번을 비교하고 2번과 3번을 비교하는 순서로 프레임의 끝번호까지 비교한다.
- 4단계 : 이전 프레임과 현재 프레임을 비교하여 윤곽선의 움직임을 통해

동작을 감지한다.

- 5단계 : 벡터의 이동 밀도를 통해 야생 조류를 탐지한다.

그림 16는 Optical Flow 알고리즘을 통해 조류의 이동 밀도를 탐지하는 예시이며, 그림 17는 조류의 움직임에 따른 픽셀 이동 밀도를 정해진 조건에 따라 탐지한 결과를 보여준다.



<그림 16> Optical Flow 알고리즘을 사용한 조류의 이동 밀도 탐지 예시.



<그림 17> Optical Flow 알고리즘을 사용한 조류 탐지 결과.

4.4 HOG + SVM 기법을 사용한 조류 탐지

Histogram of Oriented Gradients(HOG)는 이미지의 일부에서 픽셀 계산을 통해 기울기와 방향과 같은 특징을 추출하여 그래프 형태로 만드는 알고리즘이며, Support Vector Machine(SVM)은 분류 및 회귀분석에 사용되는 데이터를 분석하기 위한 감독 학습 모델이다[31].

HOG + SVM 알고리즘을 사용한 조류 탐지의 세부사항은 다음과 같다:

- 1단계 : 비디오 데이터의 조류 이미지를 수동으로 캡처한다.

- 2단계 : 캡처한 조류 이미지 세트의 이미지에서 조류 영역에 대한 HOG 특징을 추출한다.
- 3단계 : 조류 이미지에서 추출된 HOG 그래프를 SVM을 사용하여 학습한다.
- 4단계 : SVM 분류기를 사용하여 비디오 데이터에서 Bird를 분류한다.



<그림 18> HOG+SVM 알고리즘을 사용한 조류 탐지 결과.

4.5 WBBC 기법을 사용한 조류 탐지

본 논문에서 제안하는 Wild Bird Behavior Classification(WBBC)은 Faster R-CNN을 기반으로 조류를 행동에 따라 분류하여 학습하고, 탐지할 수 있는 알고리즘이다.

WBBC 알고리즘 구현의 세부사항은 다음과 같다:

- 1단계 : 비디오 데이터의 조류 이미지를 수동으로 캡처한다.
- 2단계 : 조류의 이미지 데이터 세트를 조류의 행동에 따라서 Staying Bird와 Flying Bird로 구분한다.
- 3단계 : Faster R-CNN을 사용하여 분류된 데이터 세트를 훈련하고 조류 탐지를 위한 모델을 생성한다.
- 4단계 : 전처리되어 입력되는 비디오 데이터의 프레임에서 조류를 탐지한다.



<그림 19> WBBC 알고리즘을 사용한 조류 탐지한 결과.

4.6 성능 평가

제안한 WBBC 알고리즘의 야생 조류 탐지 성능을 기존의 알고리즘들과 비교하기 위해 총 7개의 테스트 세트를 구성하였다. 각 테스트 세트는 비디오 데이터에서 추출된 프레임들이며, 하나의 테스트 세트는 20개의 프레임이다. Case 1은 간단한 환경으로 하늘에서 비행하는 조류의 비디오 클립이고, Case 2 또한 간단한 환경으로 하늘에서 비행하는 여러 마리의 조류가 등장하는 비디오 클립이다. Case 3, 4, 그리고 5는 나뭇가지, 나뭇잎, 그리고 돌과 같은 다양한 객체가 있는 복잡한 배경의 조류 비디오 클립이다. Case 6과 7은 매우 복잡한 비디오 클립으로 흔들리는 나뭇가지 위의 조류 비디오 클립이다. 단순히 탐지 성능의 비교를 위해서 기존 이미지 처리 알고리즘을 사용한 기법들은 수동으로 특징을 추출하였다.

표 4는 Case 1-7에 대한 각 알고리즘의 조류 탐지 정확도를 보여준다. Average Accuracy는 각 Case마다 20개의 프레임씩 총 140개의 프레임에 대한 야생조류 탐지 정확도의 평균을 의미한다. 표 3은 비교된 기법의 연산량을 의미하며, 초당 처리가능한 프레임의 수로 표현한다.

SURF 알고리즘의 Average Accuracy는 50.0%로 가장 낮았다. 또한 SIFT는 SURF와 유사하게 50.7 %의 Average Accuracy를 나타냈다. SIFT와 SURF를 사용한 조류 탐지에서 치명적인 문제는 조류 행동으로 인한 외형의 변화를 감지 할 수 없다는 것이다. 실험에서, 이 기법들은 수동으로 추출한 조류의 이미지와 유사한 경우만을 탐지하였다. Optical Flow를 사용한 탐지에서는 52.1 %의 Average Accuracy를 보여 주었다. 이 기술은 고정된

시점에서 움직이는 물체를 정확하게 탐지 할 수 있다는 장점이 있지만, Case 6, 7과 같이 배경이 움직이는 환경에서 조류를 탐지하는 것에는 적합하지 않았다.








HOG + SVM을 사용한 탐지는 72.8%의 Average Accuracy를 보였으며, 이 알고리즘은 다른 이미지 처리 알고리즘보다 정확도가 높았다. 그러나 다른 이미지 처리 알고리즘과 동일하게 수동으로 캡처한 이미지와 유사하지 않은 경우는 탐지하지 못하는 경향을 보였다.

WBBC 알고리즘은 Case 1과 2에서 100%의 Accuracy를 보여주었으며, Case 3, 4, 5에서는 95% Accuracy로 5% 오류가 발생하였다. 발생한 오류는 Boundary Box Error였다. Case 6, 7의 결과는 90%와 95%의 Accuracy를 보여준다. 이 경우들에서는 Boundary Box Error와 Detection Failure 오류가 발생했다. 최종적으로 제안한 WBBC 알고리즘의 Average Accuracy는 95.7%로 모든 환경에서 90% 이상의 정확도를 달성했다. 하지만 연산량의 경우 초당 7프레임을 처리 할 수 있는 연산량으로 가장 큰 연산을 요구한다.

<표 3> 비교된 알고리즘들의 초당 처리 가능 프레임 성능 비교.

	SIFT	SURF	Optical Flow	HOG + SVM	WBBC
Frames Processed Per Second	40	62	35	12	7

<표 4> WBBC 알고리즘과 기존 야생 조류 탐지 알고리즘의 비교 결과.

	#	SIFT	SUFF	Optical flow	HOG + SVM	WBBC	Image
Simple Environment	Case 1	75%	75%	90%	95%	100%	
	Case 2	85%	65%	95%	95%	100%	
Complicated Environment	Case 3	50%	55%	60%	55%	95%	
	Case 4	35%	45%	40%	70%	95%	
	Case 5	55%	60%	45%	65%	95%	
Highly Complicated Environment	Case 6	30%	30%	20%	65%	95%	
	Case 7	25%	20%	15%	65%	90%	
Average Accuracy		50.7%	50.0%	52.1%	72.8%	95.7%	

제2절 AWBR 알고리즘의 성능 평가

1. 실험 환경

우리는 AWBR 알고리즘을 평가하기 위해 폐쇄된 하나의 환경을 구성한다. AWBR 알고리즘은 유해조류가 먹이를 지속적으로 방문해야하는데, 실제 환경에는 이와 같은 실험이 오랜 시간이 걸리기 때문이다. 따라서 유해조류가 생존을 위해 위협을 학습하면서 먹이통으로 접근 할 수 있는 폐쇄된 환경을 그림 20 (a)와 같이 구성하였다. 이 환경은 실제 환경과 다르게 먹이 선택을 위한 다른 선택지가 없기 때문에 실제 환경보다는 적응하는 속도가 빠를 수 밖에 없다. 그림 20 (a)는 케이지의 모습이며 크기는 $2.5 * 4 * 8m$ 이다. 그림 20 (b)는 케이지 내부의 새집과 나무 모형, 그리고 두 개의 먹이통이 위치한다. 그림 20 (c)는 (b)에서 빨간 박스로 표시된 먹이통의 내부를 보여준다. 장치는 Raspberry Pi 3, Pi 3 카메라, 외부 배터리 및 Bluetooth 스피커로 구성된다.



(a)



(b)




(c)

<그림 20> 실험 환경. (a) 재침입 시나리오의 재현을 위해 구성한 케이지의 외형. (b) 케이지 내부 모습(빨간색 박스는 먹이통). (c) 먹이통 내부의 실험을 위해 구성한 퇴치 장치


AWBR 알고리즘의 성능을 평가하는 실험에서는 직박구리(Brown-eared Bulbul), 박새(Great Tit), 그리고 까치(Eurasian Magpie) 3종의 유해조류를 대상으로 수행하였으며, 그림 21의 (a), (b), (c)와 같다. 이 유해조류들은 실제 과수원에 침입한 조류들로 트랩을 사용하여 포획하였으며, 포획기간은 최대 7일로 실험 후에 풀어주었다. 까치의 가청 주파수는 100Hz-21000Hz이며, 직박구리와 박새의 가청 주파수는 알려져 있지 않지만 이들은 참새 중

으로 분류되기 때문에 이들의 청각 주파수가 250Hz-12000Hz라고 가정한다 [32].




<그림 21> 실험에 사용한 유해조류. (a) 직박구리(Brown-eared Bulbul). (b) 박새(Great Tit). (c) 까치(Eurasian Magpie).


또한 본 실험들에서는 서론에 언급한 것처럼 새로운 퇴치 수단이 아닌 기존의 퇴치 수단 중 소리를 사용하여 유해조류의 퇴치를 시도한다. 소리 위협은 기존에 유해조류 퇴치에 사용되던 위협 소리인, 폭음(Explosion), 천적(Natural enemy), 그리고 잡음(Noisy)과 같이 유해조류의 주파수 범위에서 자극을 줄 수 있는 소리를 선택하였다. 그림 22-24은 각 위협 소리의 특성을 시각화해서 보여준다. 폭음 소리는 그림 22과 같이 주기적으로 매우 높은 헤르츠(Hz) 영역의 소리를 발생시키며 5000Hz-22000Hz의 소리 범위를 가진다. 천적 소리는 매의 경계 울음 소리로 그림 23과 같이 2000Hz-15000Hz영역에서 지속되는 소리를 발생시키는 특징을 보여준다. 잡음 소리는 그림 24와 같이 매우 짧은 주기로 반복되는 소음을 일으키는 특징을 가지며 11000Hz-15000Hz의 범위를 보여준다.



<그림 22> 폭발(Explosion) 위협 소리의 시각화.



<그림 23> 천적(Natural enemy) 위협 소리의 시각화.



<그림 24> 잡음(Noise) 위협 소리의 시각화.


2. 유해조류 적응의 검증

이 실험에서는 직박구리를 사용하여 유해조류의 적응을 수치적으로 검증한다. 우리는 유해조류가 초기에 접하는 폐쇄된 케이지 환경에 대해 경계할 것이기 때문에 원래 먹는 것보다 적게 먹으며, 적응 할수록 원래 먹던 양을 회복할 것이라고 가정하였고, 이를 실험을 통해 검증한다.

실험은 케이지에 직박구리와 먹이를 위치시키고, 아무 자극도 하지않는 경우와 위협 소리를 주기적으로 발생시키는 경우의 직박구리의 사과 섭취량을 비교하였다. 비자극(Non-stimulus)과 자극(Stimulus) 실험은 간섭을 피하기 위해 별도로 수행되었으며, 자극 실험에 대한 위협 소리는 폭발 위협 소리를 사용하였다. 사과 섭취량은 4 시간 단위로 측정되었으며, 직박구리는 머리부터 꼬리깃까지 약 24cm 길이의 크기가 비슷한 종을 사용했다.

그림 25는 비자극과 자극환경에서 58시간동안 유해조류의 사과 섭취량 변화이며, x축은 시간당 평균 사과 섭취량 그래프(g)이며, y축은 시간이다. 자극이 없는 경우, 유해조류는 생소한 폐쇄된 케이지 환경으로 인해 처음 16시간까지 시간당 약 3-4g을 먹었다. 그리고 점차 섭취량은 증가하며, 20시간 후로는 시간당 약 5그램의 일정한 섭취량을 보여준다. 이렇게 일정한 섭취량을 보이는 상황을 직박구리가 케이지 환경에 완전히 적응한 경우라고 판단하였다. 그리고 24cm 직박구리의 Adaptation Discrimination Baseline (ADB)을 5g로 설정했다. 자극 환경에서는 ADB에 도달하는데 52시간이 걸렸으며 이는 비자극 환경보다 61.6% 느렸다. 그림 26은 실제 실험의 스냅샷이며, 빨간 박스 안의 직박구리를 확인 할 수 있다.

이 실험에서 우리는 유해조류가 반복적인 위협에 노출될 경우 학습을 통해 적응할 수 있다는 것을 검증하였다. 또한 특정 소리에 한 번 적응 하여 ADB에 도달한 유해조류는 적응 된 위협 소리를 완전히 무시하는 경향을 보이는 것을 확인 할 수 있었다.



<그림 25> 비자극(Non-stimulus)과 자극(Stimulus) 환경의 유해조류의 먹이 섭취량 변화.



<그림 26> 비자극(Non-stimulus)과 자극(Stimulus) 환경의 야생 조류의 먹이 섭취량 변화 실험의 스냅샷.

3. 소리와 볼륨의 조합에 따른 유해조류 퇴치 효과 비교

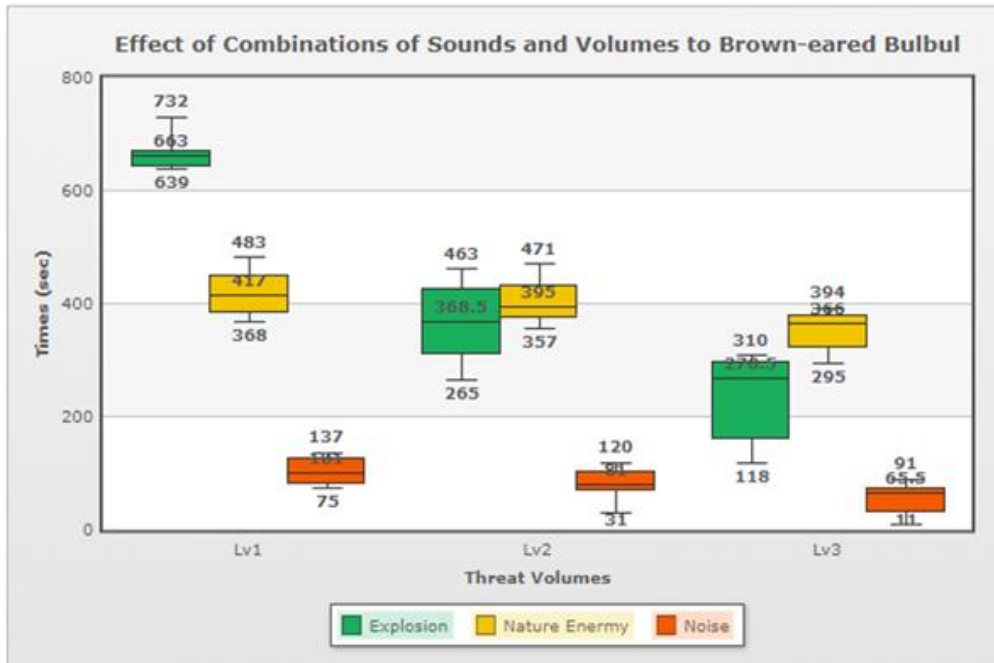
본 실험에서는 유해조류가 다양한 소리에 대해 다르게 반응 하는 것을 검증하며, 서론에서 설명한 중에 따라 같은 소리 위협에도 다른 반응이 다를 수 있음을 검증한다. 실험은 그림 20 (c)와 같이 폐쇄된 케이지의 먹이통에 사과와 실험 장치를 설치하였다. 유해조류 퇴치 장치는 유해조류가 사과에 접근하는 것을 WBBC 알고리즘을 통해 탐지할 수 있으며, 탐지시 소리와 볼륨의 조합으로 구성된 퇴치 위협 소리를 재생하였다. 각 조합은 소리(폭발, 천적, 잡음 소리)와 볼륨(Lv1, Lv2, Lv3)으로 총 9가지로 구성하였다.

우리는 직박구리와 박새와 같은 2종의 야생 조류를 실험에 사용했으며, 9가지 위협 소리 조합은 각각 10 회씩 측정되어 그림 26, 27에서 볼 수 있다. 1회의 실험 데이터는 사과를 위치한 시점부터 야생 조류가 사과를 한 번 쪼아 먹은 시점까지의 시간을 초단위로 수집한 것이다. 그래프에서 하나의 조합은 야생 조류가 위협 소리 조합에 적응하여 사과를 한 번 쪼아 먹기까지 걸린 시간의 최대값, 평균값, 최소값 및 편차를 표현한다.

그림 27는 실제 먹이통 안에 위치한 유해조류 퇴치 장치의 WBBC 기법을 통해 유해조류인 직박구리를 탐지한 스냅샷이다.

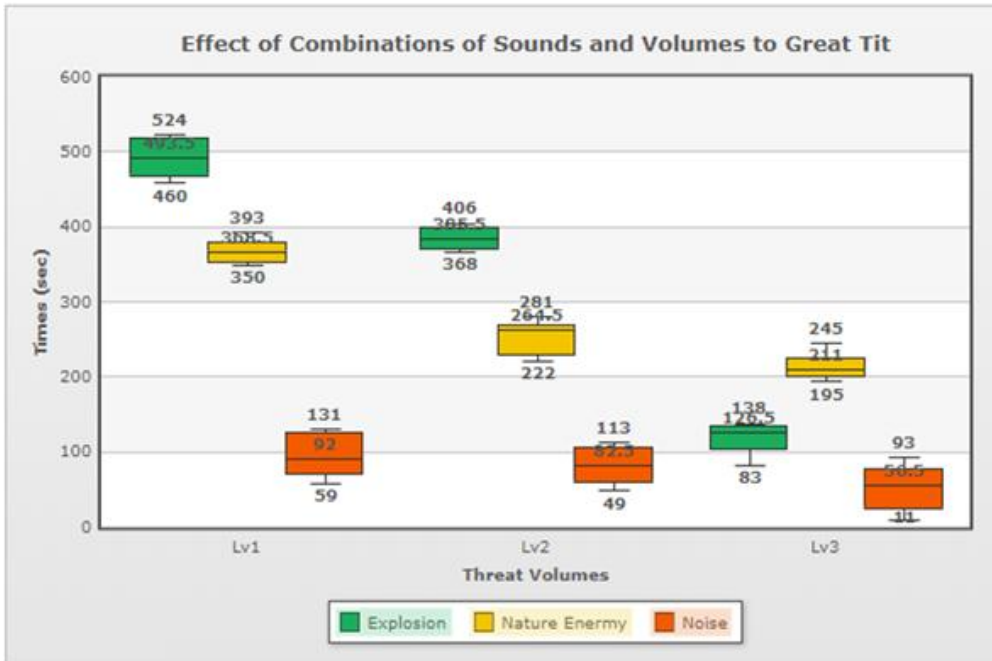


<그림 27> 소리 위협의 종류에 따른 유해조류 퇴치 효과 실험 스냅샷



<그림 28> 직박구리에 대한 위협 소리와 볼륨의 조합별 효과.

그림 28은 직박구리에 대한 위협 소리 조합의 효과를 보여준다. 직박구리가 가장 적응하지 못한, 즉 위협을 가장 많이 느끼는 조합은 폭발(Explosion) 소리와 볼륨 Lv1이다. 이 결과는 직박구리의 최대 가청 주파수에 22000Hz 근접하는 폭발 위협 소리 주파수와 관련이 있다고 판단되며, 이 야생 조류는 폭발 소리 조합에 가장 민감하게 반응하였으며, 볼륨에 따라서 선형적인 보호 시간을 보여준다. 볼륨 Lv1과 Lv2의 차이는 45.5%이고, 볼륨 Lv2와 Lv3의 차이는 27.6%이다. 천적(Natural enemy) 소리의 위협 조합은 폭발 위협 사운드보다 볼륨의 영향을 받지 않는 경향을 보인다. 볼륨 Lv1과 Lv3의 차이는 13.7%에 불과하며, 이는 볼륨 수준에 관계없이 천적의 소리 조합이 직박구리에게 위협이 된다는 것을 의미한다. 잡음(Noise) 소리의 조합은 대부분의 실험에서 작은 효과를 보여준다.



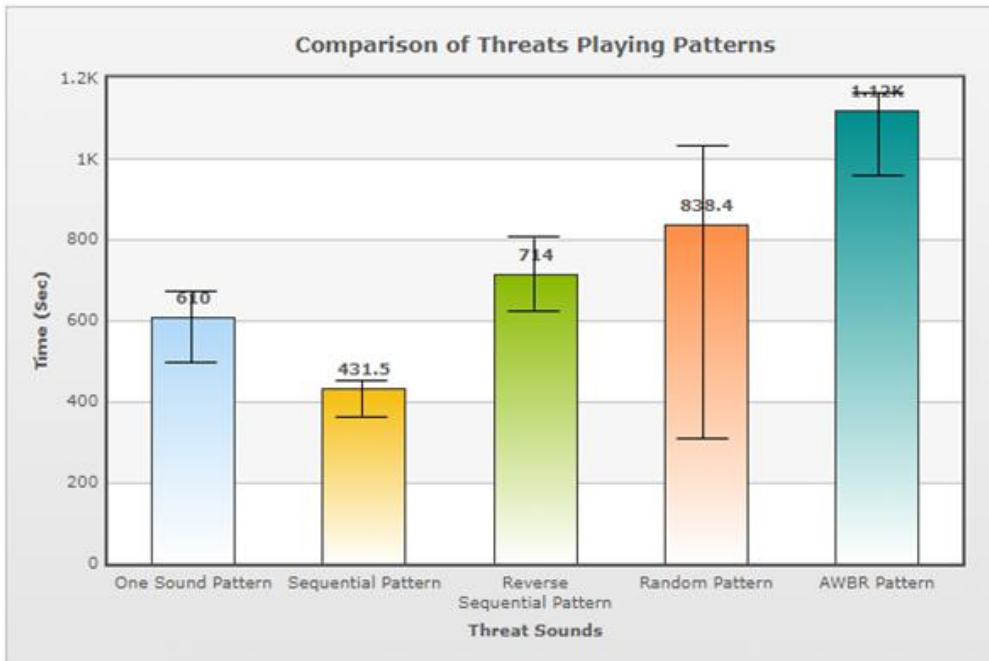
<그림 29> 박새에 대한 위협 소리와 볼륨의 조합별 효과.

그림 29은 박새에 대한 동일한 실험의 결과를 보여준다. 이 유해조류는 대부분의 경우 직박구리보다 빠르게 소리 조합에 적응하였다. 박새에게 가장 큰 위협이 되는 소리 조합은 폭발 소리와 볼륨 Lv1의 조합이었다. 또한 직박구리와 다르게 폭발 소리와 천적 소리 모두에서 볼륨 레벨의 영향을 받는다. 폭발 소리의 볼륨 Lv1과 Lv3 사이의 위협 효과 차이는 75.5%이며, 천적 소리의 볼륨 Lv1과 Lv3 사이의 위협 효과 차이는 43.8%입니다. 잡음 소리의 조합은 박새에게도 거의 효과가 없었다. 또한 박새는 직박구리보다 실험 결과 편차들이 작았다. 이것은 직박구리는 개체내의 성격 차이가 박새보다 크다는 것을 의미한다.

이 실험에서 유해조류는 종에 따라 각 위협 소리 조합에 다르게 반응하는 것을 확인 할 수 있었으며, 위협에 적응하는 시간 또한 종별로 개체별로 다르다는 것을 확인하였다. 따라서 이렇게 다양한 특성과 환경적인 변수들이 모두 고려된 딥러닝 모델을 생성하는 것은 매우 어려운 일이다. 우리는 이 실험 결과를 근거로 모델을 생성하는 방법이 아닌 실제 현장의 경험만을 고려할 수 있는 강화학습 이론과 몬테카를로 이론을 활용하여 유해조류를

학습할 수 있는 AWBR 알고리즘을 제안하였다.

4. AWBR 알고리즘의 성능 평가



<그림 30> AWBR 알고리즘과 기존 재생 패턴들(One Sound Pattern, Sequential Pattern, Reverse Sequential Pattern, Random Pattern)의 비교.

이 실험은 AWBR 알고리즘의 성능을 평가하기 위해서 4장 2절 3의 실험에서 생성된 소리와 볼륨의 조합을 사용하여 퇴치 소리를 재생할 수 있는 패턴을 생성하였다. 그리고 실제로 이 여러 패턴들(One Sound, Sequential, Reverse Sequential, 그리고 Random Pattern)은 기존 퇴치 장치들이 위협 소리를 재생하는 기법들이다. 실험 방법은 유해조류와 실험 장치 그리고 먹이를 케이지 내부에 위치시키고, 실험 장치가 WBBC 알고리즘을 사용하여 유해조류를 탐지한다. 그리고 탐지된 경우 각 패턴에 따라 유해조류 퇴치 소리 조합을 재생한다. 1회의 실험은 야생 조류가 사과를 한 번 쪼아 먹을 때까지의 시간을 측정하며, 이 시간을 보호 시간이라고 한다. 각 패턴의 보호 시간은 과수원에 침입하여 포획되는 직박구리, 박새, 그리고 까치를 대상

으로 5번씩 측정되었다.

그림 30은 위협 소리들의 조합을 패턴별로 재생하고 보호시간에 대한 결과를 보여준다. One Sound Pattern은 야생 조류가 탐지 된 경우, 단일 소리만 재생한다. 이 때 사용한 소리는 가장 효과가 좋았던 폭발의 소리와 볼륨 Lv1을 사용했다. 이 패턴은 평균 610초의 보호 시간을 보여주었다. Sequential Pattern은 4장 2절 3의 실험 결과에 따라 소리를 효과별로 정렬하고 가장 약한 위협 사운드부터 순차적으로 재생한다. 예를 들면, 잡음+볼륨 Lv3, 노이즈+볼륨 Lv2, 잡음+볼륨 Lv1, 천적+볼륨 Lv3, 폭발+볼륨 Lv3, 천적+볼륨 Lv2, 폭발+볼륨 Lv2, 천적+볼륨 Lv1, 폭발+볼륨 Lv1 의 순서와 같다. 이 패턴은 효과가 강한 소리가 재생되기 전에 효과가 약한 소리에 이미 야생 조류가 적응하는 결과를 보였으며, 평균 431.5 초의 보호 시간을 보여준다. Reverse Sequential Pattern은 Sequential Pattern의 역순이며, 위협 소리 조합은 효과가 가장 강한 순서로 재생되었다. 이 패턴은 평균 714초의 보호 시간을 보여주며 One Sound 패턴보다 좋은 결과를 보여준다. Random Pattern은 위협 소리 조합들을 임의의 순서로 재생하는 패턴이다. 보호 성능은 평균 838.4초를 보여주며 다른 패턴들에 비해 평균적으로 높은 결과를 보여주지만, 가장 낮은 보호 시간과 가장 높은 보호 시간의 편차가 큰 특징을 보여준다. 하지만 과수원의 과수를 보호해야한다는 측면에서는 이 패턴에 대해 신뢰가 어려운 문제가 있다.

우리는 Reverse Sequential Pattern과 Random Pattern의 결과에서 유해 조류에게 효과가 강한 하나의 소리를 재생하는 것보다 효과가 조금 약하더라도 다른 여러 소리를 재생하는 것이 적응 방지에 효과적이라는 것을 검증하였다.

마지막으로 AWBR 알고리즘을 사용한 패턴의 최고 성능은 평균 1128 초로 One Sound Pattern보다 46%, Reverse Sequential Pattern보다 37% 더 좋은 결과를 보였으며, 성능의 편차 또한 다른 패턴에 비해 크지 않은 것을 확인 할 수 있다. 이 결과는 패턴의 조합 중에서 좋은 효과를 보였던 Reverse Sequential Pattern이나 Random Pattern처럼 유해조류를 고려하지 않고 위협 소리를 재생하는 것보다 유해조류가 적응하는 과정을 학습하여 위협 소리 조합을 재생하는 것이 더 효과적이라는 실험 결과를 도출하였다.

제5장 결론

본 논문에서는 유해조류로부터 발생하는 농작물 피해를 줄이기 위해 딥 러닝과 강화학습을 활용한 적응을 방지하는 유해조류 퇴치 시스템을 제안했다. 과수원과 같이 복잡한 농업 환경에서도 야생 조류를 정확하게 탐지 할 수 있는 Faster R-CNN을 활용한 Wild Bird Behavior Classification(WBBC) 알고리즘을 제안하였으며, 탐지 결과를 기반으로 유해조류의 반응을 학습하고 적응을 방지할 수 있는 강화학습과 몬테카를로 이론에 기반한 Anti-adaptation Wild Birds Repelling(AWBR) 알고리즘을 제안하였다.

먼저, WBBC 알고리즘은 야생 조류를 행동으로 분류하여 학습시키는 것으로 딥 러닝에서 발생할 수 있는 오버피팅 문제를 줄일 수 있으며, 우리의 실험 환경에서 3.6%의 정확도 개선을 보여주었다. 기존 SIFT, SURF, Optical Flow, HoG+SVM을 사용한 야생 조류 탐지 기법과 정확도 수치만으로 비교를 하였을 때, WBBC 알고리즘은 95.7%의 가장 높은 평균 정확도를 달성하였다. 추가적으로 WBBC 알고리즘은 유해조류의 종이나 환경이 바뀌어도 새의 특징을 학습하여 탐지하는 방법이기 때문에 어느정도의 정확도를 보여주지만, 기존 알고리즘의 경우 새로운 환경과 조류의 외형에 대해서 정의하지 않으면 탐지 할 수 없는 문제가 있다.

AWBR 알고리즘을 WBBC 탐지 기법을 기반으로 퇴치 위협을 학습하는 유해조류에 대한 반응을 Long-term과 Short-term으로 구분하여 적응을 판단한다. 그리고 적응 정도에 따라 위협 소리를 가장 적응이 어려운 형태로 재상하는 것을 통해 적응을 방지 할 수 있음을 실험 결과를 통해 검증하였다. 우리는 실제로 과수원 주변에서 포획된 유해조류인 직박구리, 박새, 그리고 까치를 대상으로 실험을 수행하였으며, 동일한 퇴치 위협 소리를 재생 패턴별로 분류하여 수행한 실험에서 AWBR 알고리즘을 사용한 패턴에서 평균 43.5% 더 긴 보호 시간을 달성하였다. 야생 조류가 지속해서 재방문 할 수 있는 시나리오의 재현을 위해서 유해조류의 다른 먹이 선택지를 없앤 폐쇄된 케이지 환경에서 실험을 수행했기 때문에 다른 먹이 선택지가 있는

실제 환경에서는 더 좋은 결과를 얻을 수 있을 것이라고 생각한다.

하지만 WBBC 알고리즘을 비전 센서를 기반으로 하기 때문에 광량이 적어지는 야간의 경우 시야가 한정적인 단점이 있다. 과수원과 같은 농업 환경에 침입하는 대다수의 유해조류가 주행성이긴 하지만 그럼에도 불구하고 해가 지기 바로 전과 같은 상황에서는 탐지가 어려운 문제가 남아있다. 또한 우리는 유해조류 탐지 정확도를 위해서 Faster R-CNN과 VGG-16모델을 사용하여 높은 정확도를 달성하였지만, 표 3의 결과와 같이 WBBC기법은 본 실험 환경에서 초당 7프레임 정도 밖에 처리하지 못하는 성능을 가지고 있다. 실제로 동영상은 초당 24프레임 정도로 구성되며, 이러한 동영상에서 탐지를 시도할 경우 입력되는 전체 프레임을 실시간으로 처리하지는 못하기 때문에 정확도가 떨어질 수 있는 문제가 남아있다. 그리고 AWBR 알고리즘의 경우, 다양한 이전 퇴치 기법들보다 좋은 성능을 보였지만 유해조류에 대한 학습 데이터가 없는 경우에 대해 임의로 대응하는 구조를 취하기 때문에 초기에는 성능을 보장 할 수 없는 문제 또한 존재한다. 향후 추가적인 연구들을 통해 이러한 문제들을 해결해야한다.

참 고 문 헌

<서양문헌>

1. Lee, C.W.; Muminov, A.; Na, D.Y.; Jeon, H.S. Implementation of Vision-based Wild Bird Detection and Repelling System using RaspberryPi. In Proceedings of the Korean Society of Computer Information Conference , 2018, 26(2), 506–507.
2. Neal, B.; Jennifer, B.; Sharon, B.; Colleen, M.L. Amazing Birds. The Cornell Lab of Ornithology. Wayne-Finger Lakes BOCES, USA. 2009
3. Muminov, A.; Jeon, Y.C.; Na, D.Y.; Lee, C.W.; Jeon, H.S. Development of a Solar Powered Bird Repeller System With Effective Bird Scarer Sounds. In Proceedings of the 2017 International Conference on Information Science and Communications Technologies (ICISCT). 2017, 1, 1 - 4
4. Turner, P.R. Bird Repelling Device. United States patent application US 29/651,055. 2019, Mar 5.
5. Lee, S.W; GES Co., ltd., assignee; Device For Repelling Wild Animals And Harmful Animals Using Laser. United States patent US 9,706,765. 2017, Jul 18.
6. Simon, G. A Short Overview of Bird Control in Sweet And Sour Cherry Orchards–Possibilities of Protection of Bird Damage And Its Effectiveness. International Journal of Horticultural Science. 2008, 14, 107 - 111.
7. Olivera, L.; Rodríguez, E.; Ceretta, S.; Beyhaut, E. Bird Repellent Applied To Soybean Seed: Compatibility With Inoculant And Residuality in Cotyledons. Agrociencia (Montevideo). 2016, 20, 51 - 60.
8. Mofokeng, M.A.; Shargie, N.G. Bird Damage And Control Strategies

- in Grain Sorghum Production. International Journal of Agricultural and Environmental Research. 2016, 2, 264 - 269.
9. Ahmad, S.; Saleem, Z.; Jabeen, F.; Khan, H.A.; Yaqub, S.; Samiullah, K.; Mubarik, S.; Irfan, M.; Shaheen, T. Effectiveness of Methylantranilate And Anthraquinone as Repellent Against House Crows (*Corvus splendens*) On Wheat Seeds And Seedlings In Captivity. Pakistan Journal of Zoology. 2016, 5, 48.
 10. Curtis, P.D.; Wise, K.L.; Cummings, J.; Gabriel, A.D.; Ganoe, K.; Miller, J.J.; Hunter, M.E.; O'Neil, K.A.; Lawrence, J.R.; Cerosaletti, P.E.; Dewing, D.R. Field Evaluation of Anthraquinone Treatment To Reduce Corn Seedling Damage By Birds. Crop Protection. 2019. 123, 59-62.
 11. Ma, D. Study On The Transmission Line Bird. In Proceedings of the 2017 5th International Conference on Frontiers of Manufacturing Science and Measuring Technology (FMSMT 2017); Atlantis Press. 2017, 130, 32-44.
 12. Zhao, Z. New Type Intelligent Infrared Driving Bird Device. In Proceedings of the 7th International Conference on Education, Management, Information and Mechanical Engineering (EMIM 2017); Atlantis Press. 2017, 130, 54-60.
 13. Fang, Q.; Canbing, L. Design of transmission line solar ultrasonic birds repeller. In Proceedings of 2011 IEEE Power Engineering and Automation Conference, 2011, 1, 217-220.
 14. Moon, J.R. Effects of birds on radar tracking systems. In proceedings of IEEE Conference. 2002, 490, 300 - 304.
 15. Song J; Ning H; Chen W; Liu J; Li J. Bird flying track estimation based on single marine radar. In proceedings of 2008 Third International Conference on Communications and Networking in China. 2008, 1, 1122-1126.
 16. Stowell D.; Wood M.; Stylianou Y.; Glotin H. Bird detection in

- audio: a survey and a challenge. In proceedings of 2016 IEEE 26th International Workshop on Machine Learning for Signal Processing (MLSP). 2016, Sep 13, pp. 1–6.
17. Marini A.; Turatti A.J.; Britto A.S.; Koerich A.L. Visual and acoustic identification of bird species. In proceedings of 2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2015, Apr 19, 2309–2313.
 18. Karmaker D.; Schiffner I.; Strydom R.; Srinivasan M.V. WHoG: A weighted HoG-based scheme for the detection of birds and identification of their poses in natural environments. In proceedings of 2016 14th International Conference on Control, Automation, Robotics and Vision (ICARCV). 2016, Nov 13, 1–7.
 19. Li Y.; Yin Y.; Xu B. Bird Objects Detection and Tracking on the Wild Field Circumstance. In proceedings of 2009 WRI World Congress on Computer Science and Information Engineering. 2009, 6, 533–536.
 20. Li C.; Hu H.; Zhang B. Evaluation of super-resolution on bird detection performance based on deep convolutional networks. In proceedings of 2017 IEEE Global Conference on Signal and Information Processing (GlobalSIP). 2017, Nov 14, 803–807.
 21. Takeki A.; Trinh T.T.; Yoshihashi R.; Kawakami R.; Iida M.; Naemura T. Detection of small birds in large images by combining a deep detector with semantic segmentation. In proceedings of 2016 IEEE international conference on image processing (ICIP). 2016, Sep 25, 3977–3981.
 22. Zhang X.Y.; Wu X.J.; Zhou X.; Wang X.G.; Zhang Y.Y. Automatic detection and tracking of maneuverable birds in videos. In proceedings of 2008 International Conference on Computational Intelligence and Security. 2008, 1, 185–189.
 23. Sutton, R.S.; Barto, A.G. Reinforcement learning: An introduction;

- MIT press, 2018;
24. Sutton, R.S.; Barto, A.G. Introduction to reinforcement learning; MIT press Cambridge, 1998; Vol. 2;.
 25. Lin, Y.; Wang, C.; Wang, J.; Dou, Z. A. Novel Dynamic Spectrum Access Framework Based On Reinforcement Learning For Cognitive Radio Sensor Networks. *Sensors*. 2016, 16, 1675.
 26. Welinder P.; Branson S.; Mita T.; Wah C.; Schroff F.; Belongie S.; Perona, P. Caltech-UCSD Birds 200. California Institute of Technology. CNS-TR-2010-001. 2010.
 27. Simonyan K.; Zisserman A. Very Deep ConvNets for Large-Scale Image Recognition.
 28. Lowe D.G.; Distinctive image features from scale-invariant keypoints. *International journal of computer vision*. 2004, 60(2), 91-110.
 29. Bay H.; Ess A.; Tuytelaars T.; Van Gool L. Speeded-up robust features (SURF). *Computer vision and image understanding*. 2008, 110(3), 346-59.
 30. Maruyama K.; Saitoh T.; Konishi R. Bird tracking and flapping motion recognition for monitoring system. In *proceedings of 2009 International Conference on Control, Automation and Systems (ICCAS-SICE)*. 2009, 3613-3618.
 31. Perdersoli M.; Gonzalez J.; Chakraborty B.; Villanueva J.J. Boosting histograms of oriented gradients for human detection. In *proceedings of Computer Vision: Advances in Research & Development (CVCRD)*. 2007, 1-6.
 32. Beason, R.C. What Can Birds Hear?. In *Proceedings of the Vertebrate Pest Conference*. 2004, 21, 92-96.

국문초록

유해조류의 적응을 방지하기 위한 딥러닝과

강화학습을 활용한 퇴치 시스템의 구현

인간이 경작을 시작한 이래로 유해조류는 논, 밭, 과수원과 같은 다양한 농업 환경에 심각한 피해를 입히고 있다. 유해조류는 인간의 생활에 해를 입히는 조류를 가리키는 명칭으로 비둘기, 참새, 까치, 직박구리, 그리고 박새와 같은 조류가 대표적이다.

이러한 유해조류를 퇴치하기 위한 다양한 퇴치 방법과 장치들이 연구되어졌지만 여전히 유해조류로부터 매년 큰 피해를 입고 있다. 이는 유해조류가 퇴치 위협들을 빠르게 학습하고 적응할 수 있는 생물학적인 특징을 가지고 있기 때문이다. 따라서 유해조류로부터 발생하는 피해를 줄이기 위해서는 이러한 유해조류의 적응을 방지할 수 있는 방식의 퇴치 기법 연구가 필요하다.

본 논문에서는 유해조류의 적응을 방지하기 위해 딥러닝과 강화학습을 활용한 퇴치 시스템을 제안한다. 먼저 다양한 환경에서 유해조류를 탐지하기 위해 비전센서를 사용하며, 비전 기반 딥러닝(Deep Learning) 알고리즘인 Faster R-CNN을 활용하여 유해조류를 행동에 따라 분류하는 Wild Bird Behavior Classification(WBBC) 알고리즘을 제안한다. 그리고 이 탐지 기법을 기반으로 유해조류의 반응을 Long-term과 Short-term으로 구분하여 적응을 판단하고, 유해조류의 반응에 따라 가장 적응할 수 없는 형태의 퇴치 소리 위협를 가하는 방식의 기법을 제안한다. 위협 수단에 적응하려는 유해조류의 반응을 학습하기 위해서 강화 학습(Reinforcement Learning)과 몬테카를로(Monte Carlo) 이론을 활용한 Anti-adaptation Wild Birds Repelling(AWBR) 알고리즘을 제안한다.

우리는 제안한 WBBC와 AWBR알고리즘을 실제 유해조류인 직박구리, 까치, 박새를 대상으로 실험을 통해 검증하였다. WBBC 알고리즘은 일반

적으로 학습시키는 방법보다 3.6% 개선된 정확도를 보였으며, 다양한 실험 환경에서 평균 95.7%의 탐지 정확도를 달성하였다. 또한 AWBR 알고리즘은 기존에 사용되던 소리 재생 기법들보다 평균 43.5% 더 긴 시간 동안 유해조류를 퇴치하고 적응을 방지하였다. 이 결과를 통해 실제로 딥러닝과 강화학습 기법을 활용하여 유해조류 피해를 경감시킬 수 있음 검증하였다.